# 模型假设

为简化问题，本文做出以下假设：

假设 1：同一字段在样本之间具有可比的测量含义。附件 1 采用统一字段，附件 8 支持识别 37 个 log10 字段与 33 个原尺度字段，但字段尺度可识别不代表每个单元格一致。本文保留附件 1 给定值；若发现批次或单元格冲突，则单列核验，涉及绝对浓度的解释仅使用逐条确认的观测。

假设 2：在没有酒厂、批次及重复配方标识时，将每款啤酒作为一个观测单位。beer 字段完整且唯一，支持样本对齐；若后续获得同厂或同批信息，则改用分组交叉验证，并重新估计泛化误差。

假设 3：少量缺失不使整款样本失去预测价值，且缺失位置可能包含测量流程信息。输入共 73 个缺失单元，涉及 63 行 9 列，因此采用折内中位数填补并保留指示。若缺失机制明显依赖未观测浓度或系统故障，则补做删失模型或多重插补分析，降低有关预测的可信度。

假设 4：附件 4 中的连续值保留各目标内部的相对强弱顺序，可用于监督学习。附件 3 给出 0—6 评分定义，但没有完整的评委中心化、缩放参数，故不假设原始均分可逆恢复；若获得原始评分，改在原始量表建模并重新评价映射。

假设 5：当前样本覆盖范围内，不同感官家族可共享部分预测信息。五个家族和重复折内预测支持估计共享及组内权重，固定 0.5 收缩用于约束小组方差；若外部样本或未见风格出现结构漂移，则重新校准、分组验证或拒绝外推。