问题二模型建立与求解

问题二分析

问题二要求对 50 个感官维度分别给出 3 个关键单体化合物，并同时论证结果的统计稳定性与化学合理性。附件 1 提供 250 款啤酒的 231 项化学及理化测量，附件 2 给出同一批字段的 Spearman 共表达矩阵，附件 4 提供 50 维标准化感官值。候选变量数与样本量接近，化合物又因共同代谢途径而高度共线，因此边际相关靠前并不等同于独立贡献，更不能直接解释为因果作用。

本题的难点有三：一是共线字段会在重采样中相互替代；二是啤酒风格同时影响化学组成和感官评分，可能制造风格间伪关联；三是部分缺陷味与细分香气的折外可预测性较弱。为此，本文先冻结 218 个严格单体候选，在相同的 10 次重复、每次 3 折外层划分下比较边际相关、稀疏回归、图正则回归和非线性条件归因，再融合总关联、分层自助、风格内校正与留一风格四类证据。统计排名冻结后，才使用阈值、OAV、同名锚点和化学文献分级，不让已知机理反向改变数据排名。

问题二模型

数据口径与候选范围

附件 1 与附件 4 按 beer 字段一一对齐，形成 250×231 的输入矩阵和 250×50 的连续感官矩阵。问题二不使用 beer_id 连接，不把风格字段作为候选化合物，也不对附件 1 中已给出的 log10 字段重复取对数。73 个缺失单元仅在相应训练子样本内用中位数填补，缺失位置在预测模型中保留指示。

候选资格先于统计建模冻结。色度、pH、苦度、蛋白质、总糖、热量、总酯、总酸、总硫及其他聚合或理化指标共 13 项不属于严格单体化合物，只参与全因素敏感性检查，不进入题面要求的最终 Top-3。严格候选因此为 218 项；化学名称由字段映射表与附件 8 逐项核对。表 1 概括数据和证据边界。

表 1 问题二数据契约与证据边界

项目	审计结果	处理方式	解释边界
样本与目标	250 款、50 维	固定 10×3 外层划分	逐目标折外评价

项目	审计结果	处理方式	解释边界
输入字段	231 项、73 个缺失	训练子样本内填补	不删除含缺失样本
严格候选	218 个单体	排除 13 个聚合/理化指标	全因素仅作敏感性
共表达矩阵	231×231 Spearman	描述图与折内图分开	验证时不复用全量图
感官值	标准化连续值	按附件尺度建模	不声称恢复原始 0—6 分
化学证据	阈值、来源、异味、文献	排名冻结后追加	不作因果解释

记第 i 款啤酒的化学向量为 x_i，第 j 个标准化感官值为 y_ij。关键化合物识别以式(1)所示预测关系为共同评价对象，但最终名次由相互独立的统计证据融合决定，而不是直接把某一模型的重要性当作因果效应。

$$y_{ij}=f_j(x_i)+\varepsilon_{ij},\qquad i=1,\dots,250,\qquad j=1,\dots,50 \tag{1}$$

边际关联、稀疏回归与折内图正则

第一类证据为逐目标 Spearman 边际关联。它保留单调非线性且对异常值较稳健，式(2)将化学字段和感官值的样本秩相关标准化。所有排名均先过滤为 218 个严格单体候选。

$$\rho_{kj}=\frac{\sum_{i=1}^{n}\left(R_k-\overline{\square}\right)\left(R_j-\overline{\square}\right)}{\sum_{i=1}^{n}\left(R_k-\overline{R_k}\right)^{2}{}^{1/2}\sum_{i=1}^{n}\left(R_j-\overline{R_j}\right)^{2}{}^{1/2}} \tag{2}$$

第二类证据为 ElasticNet 条件稀疏系数；第三类为加入有符号归一化图拉普拉斯的稀疏回归。图矩阵在每个外层训练折内重新估计，负边保留方向，缺失填补和标准化也只使用训练折。对目标 j，图正则目标函数写为式(3)。其中 L_s 为有符号图拉普拉斯，λ_1 控制稀疏度，λ_G 控制共表达邻居的系数平滑。

$$\hat{\beta}_j=\ arg\ \ min\frac{1}{2n}\left(y_j-X\hat{\beta}_j\right)^2+\lambda_1\|\beta\|_1\ +\lambda_G\beta^T L_s\beta \tag{3}$$

图正则模型用于检验代谢共表达结构是否提高预测与排名稳定性。若折外误差没有改善，图结构仍可用于模块联合置换和解释，但不据此宣称预测增益。

非线性条件归因

为补充线性稀疏模型，本文使用 ExtraTrees 建立独立的非线性归因验证器。字段置换限制在最强折内 Spearman 邻居的分位组内，共表达模块则整组联合置换；这两种操作分

别降低条件分布破坏和模块内替代造成的重要性错配。若置换字段 k 后目标 j 的验证 MAE 上升，则式(4)的条件误差增量为正。

$$\Delta_{kj}^{\,cond}=\ MAE\left(y_j,\hat{f}\left({}_jX_{-k},\hat{x}_k\right)\right)\ -\ MAE\left(y_j,\hat{f}\left(X\right)_j\right) \tag{4}$$

非线性验证器采用与问题一相同的外层划分，但独立拟合并独立评价。当前阶段不把问题一的折外数组当作已训练预测器，也不把线性系数、树置换量和边际相关的数值直接相加。

四路稳健秩融合

三类基础方法先形成总关联共识，随后与分层自助稳定排名、风格校正排名、留一风格保留排名共同组成四路证据。对每个目标和候选，先比较四路 Top-10 与 Top-3 支持数，再计算式(5)的倒数秩分数；r_ℓkj 表示候选 k 在第ℓ类证据中对目标 j 的名次。

$$S_{kj}=\sum_{\ell=1}^{4}\frac{1}{60+r_{\ell kj}} \tag{5}$$

稳定性检验在 22 种啤酒风格内保持样本数进行 500 次有放回抽样。每次重新完成预处理、候选排序和方法融合，候选的入选频率按式(6)计算。与此同时，逐一删除 22 种风格并重算排名，以检验某一风格是否主导关系。

$$\hat{\pi}_{kj}=\frac{1}{B}\sum_{b=1}^{B}I\left(k\in T_{bj}\right) \tag{6}$$

化学合理性与证据分级

统计 Top-3 冻结后，才依据同名锚点、描述词特异性、附件来源/老化/异味注释及同行评议文献进行化学核验。仅当附件 8 同时提供原始校准浓度 c_k 和同字段、同单位感知阈值 τ_k 时，才按式(7)计算气味活性值。附件 1 中的 log10 数值不直接除以阈值。

$$OAV_k=\frac{c_k}{\tau_k},\tau_k>0 \tag{7}$$

A 级表示统计关系较稳健且有直接身份或特异描述词证据；B 级表示统计与化学类别证据较完整；C 级至少有一侧证据但特异性不足；D 级为弱预测背景或缺少特异化学支持。OAV 达到 1 仅说明单体浓度达到阈值量级，不排除混合物协同、掩蔽、基质与个体差异。

问题二求解

交叉验证与模型比较

所有监督模型复用问题一冻结的 10 次重复、每次 3 折外层划分；每个重复中 250 款啤酒各作为一次验证样本。参数、缺失填补、图结构、风格均值和条件分组均只由外层训练折估计。表 2 报告六种方法的重复宏平均结果，图 1 给出共表达描述图的阈值敏感性，图 2 同时展示预测性能和最终排名对四路证据的一致性。

表 2 相同外层划分下的候选模型性能

方法	R^2（均值±SD）	MAE（均值±SD）	RMSE	Spearman
全局均值	-0.0081±0.0024	0.4173±0.0005	0.5690	-0.0576
Spearman Top-3	0.1064±0.0043	0.3843±0.0010	0.5273	0.2969
PLS/VIP	0.2089±0.0069	0.3556±0.0015	0.4890	0.4023
ElasticNet	0.2086±0.0046	0.3529±0.0012	0.4903	0.3917
有符号图 ElasticNet	0.2084±0.0047	0.3530±0.0013	0.4905	0.3919
ExtraTrees 条件归因	0.2359±0.0058	0.3422±0.0011	0.4794	0.4144

ExtraTrees 条件归因的宏平均 R^2、MAE 和 Spearman 分别为 0.2359、0.3422 和 0.4144，10 次重复的 MAE 均优于 ElasticNet。图正则模型相对 ElasticNet 的 MAE 反而增加 0.00011，Top-3 虽总体接近，但不支持“加入图惩罚即可提高预测精度”的结论。因此，图结构保留为模块与敏感性证据，非线性条件置换作为预测归因验证，最终答案采用四路稳健秩融合。

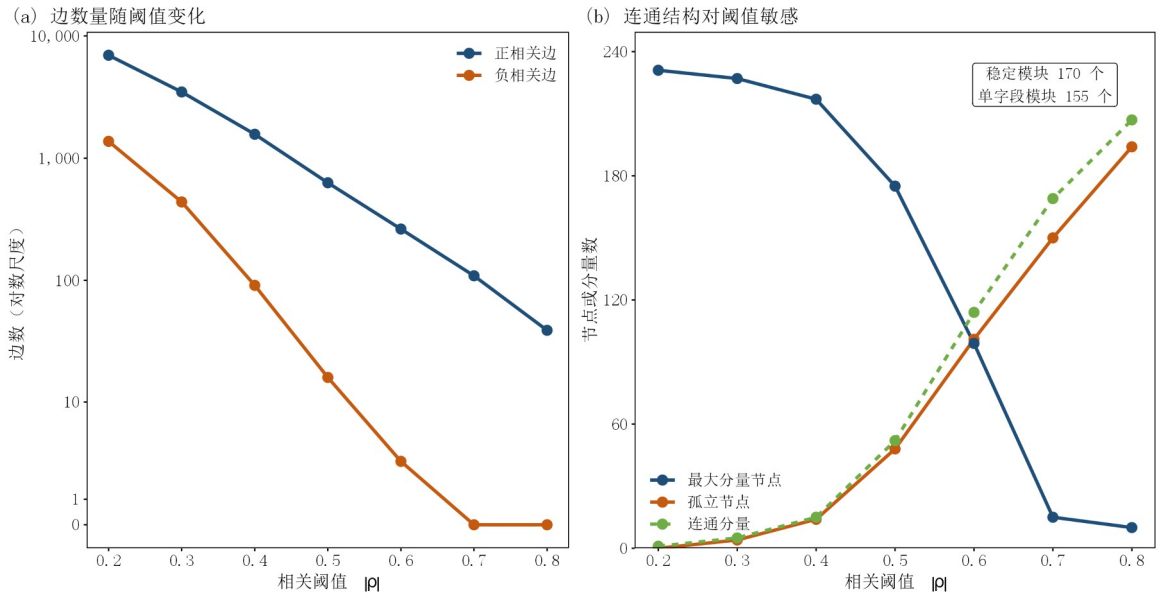


图 1 化合物共表达图的阈值敏感性

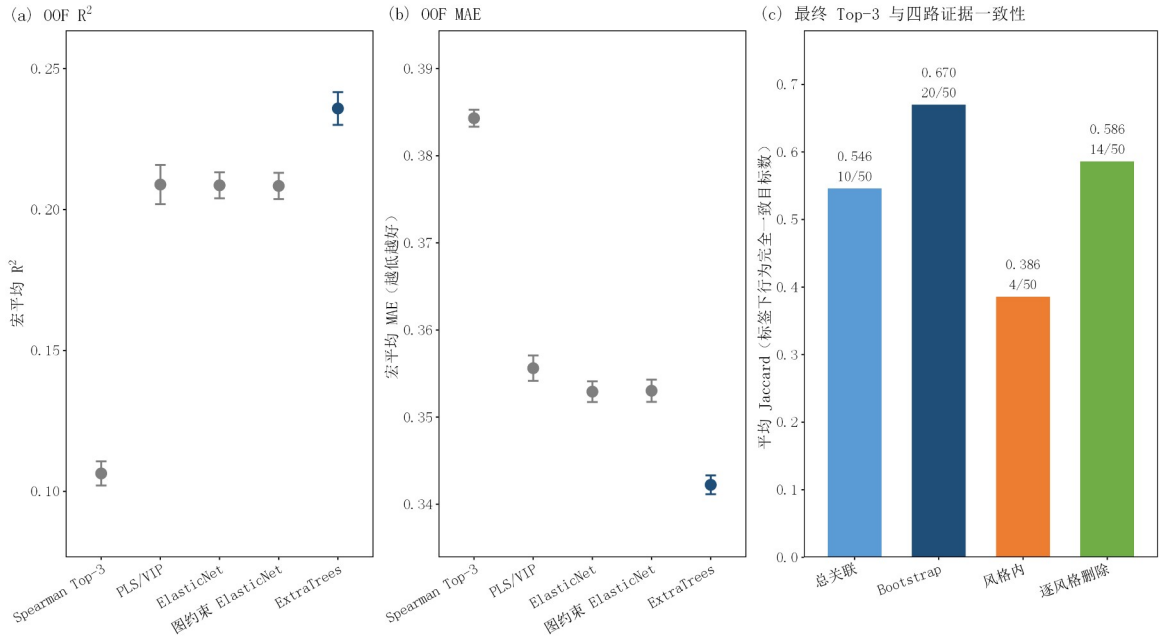


图 2 候选模型的折外性能与最终排名的一致性

稳定性与风格敏感性

500 次分层自助中，150 条聚合 Top-3 的入选频率范围为 0.182—0.992，中位数为 0.428；达到 0.60、0.70 和 0.80 的候选分别有 43、31 和 23 条。逐目标 Top-3 两两 Jaccard 均值为 0.245，说明共线字段替代和样本扰动不可忽略。稳定共聚类得到 170 个模块，其中 155 个为单字段模块，最大模块含 15 个字段。

相同参数下，未校正与风格校正 Top-3 的平均 Jaccard 为 0.264，只有 2/50 个目标完全一致。逐一删除 22 种风格后，1,100 个“风格—目标”组合的 Top-3 平均 Jaccard 为 0.523；当前 150 条候选在 22 次删除中的平均保留率为 0.641。图 3 将入选频率、留一风格保留率、预测层级与化学等级放在同一证据框架下。

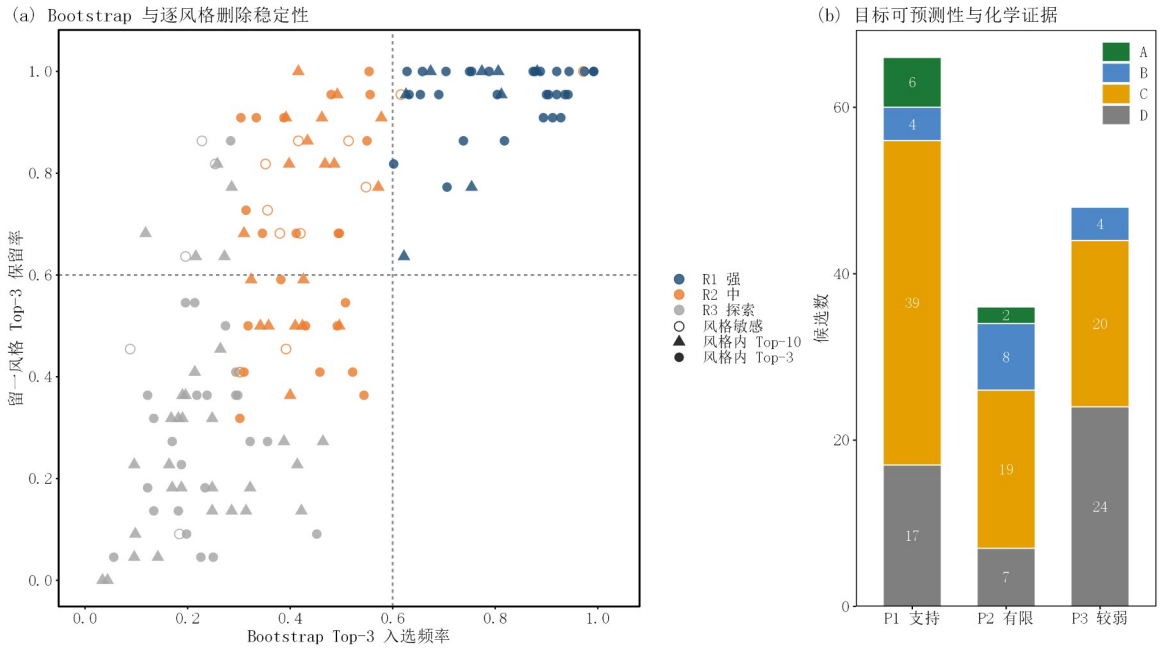


图 3 最终候选的重采样稳定性、风格敏感性与证据等级

关键化合物与化学核验

四路融合的 150 条统计 Top-3 中，强稳健、中等稳健和探索性候选分别为 38、52 和 60 条；50 个目标中，22 个折外 R^2 不低于 0.20，12 个介于 0.10 与 0.20 之间，16 个低于 0.10。题面要求每个维度输出 3 项，因此弱预测目标仍保留候选，但必须标明探索性。

表 3 化学证据较充分的代表性关键关系

感官维度	名次	关键化合物	自助入选频率	留一风格保留率	中位 OAV
指甲油样香气	1	乙酸乙酯	0.774	1.000	1.203
指甲油样风味	1	乙酸乙酯	0.878	1.000	1.203
4-乙烯基愈创木酚	1	4-乙烯基愈创木酚	0.992	1.000	0.000
酸度	1	乳酸	0.900	0.955	0.346
酒精感	1	乙醇	0.920	0.955	4.140
酒体	2	乙醇	0.812	0.955	4.140
碳酸感	3	二氧化碳	0.318	0.500	不可比
乳酸感	1	乳酸	0.992	1.000	0.346

150 条候选的 A/B/C/D 级数量分别为 8、16、78 和 48，其中 73 条具备可比的浓度与阈值，23 条的中位 OAV 不低于 1。表 3 列出的 8 条 A 级关系包括乙酸乙酯—指甲油样酯香、4-乙烯基愈创木酚—同名感官、乳酸—酸度/乳酸感、乙醇—酒精感/酒体以及二氧化碳—碳酸感。图 4 展示这些关系在四路证据中的名次和可计算的中位 OAV。

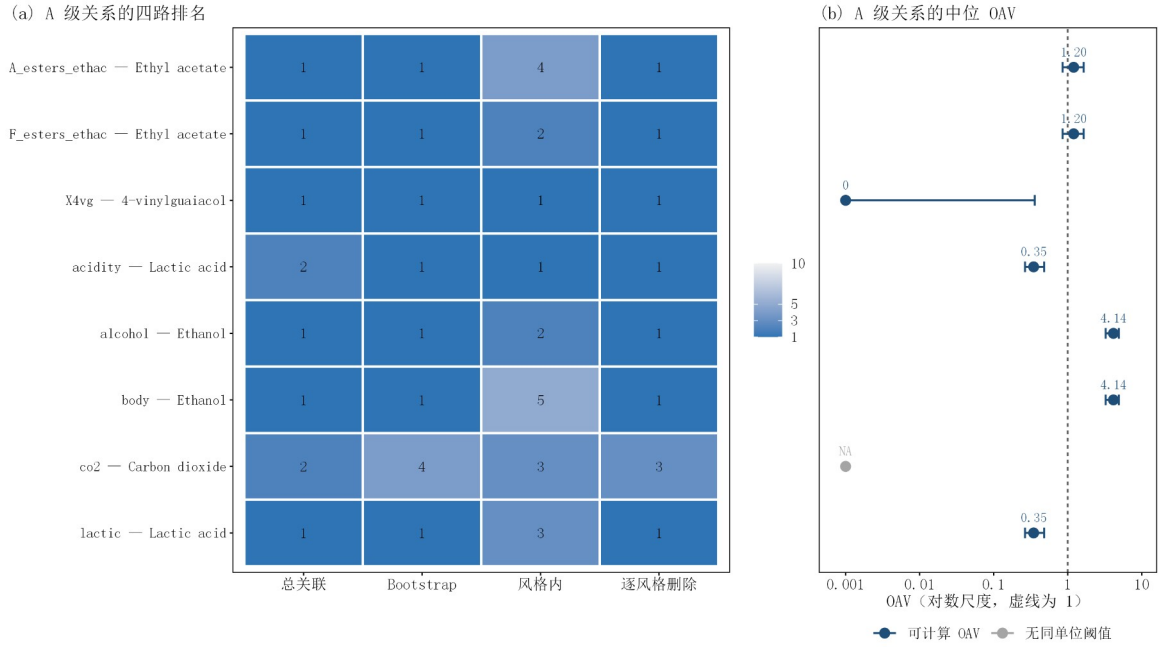


图 4 A 级化合物—感官关系的四路排名与气味活性值

模型检验与结果讨论

泄漏与稳健性检验

验证折不参与缺失填补、尺度估计、图构建、风格均值、条件分组或参数选择；全量附件 2 仅用于数据定义核验与描述图。分层自助、风格校正和留一风格三种扰动从不同方向检验名次稳定性，字段级结果同时报告所属稳定模块，避免把同模块替代误写为唯一关键成分。

模型对比与消融

边际相关的宏平均 R^2 仅为 0.1064，说明单变量排序不足以解释多维感官；PLS/VIP 和 ElasticNet 提高到约 0.209，反映共享低秩结构与条件稀疏效应。图正则未改善误差，故不作为预测主线；ExtraTrees 条件归因将宏平均 R^2 提高到 0.2359。最终四路融合不追求单一重要性数值最大，而优先保留跨方法、重采样与风格扰动下重复出现的候选。

合理性与局限

4-乙烯基愈创木酚、乙醇、乳酸和二氧化碳等直接锚点进入最终 Top-3，支持方法能够恢复部分已知关系。DMS、双乙酰和 trans-2-nonenal 的同名字段未进入前三，分别排在较后位置，因此相应目标的前三只能解释为当前样本中的预测关联，不能冒充已知缺陷化合物。

本问仍受 250 个样本、22 种不均衡风格、共线替代和标准化感官信号限制。16 个弱预测目标的 Top-3 为题面要求下的探索性输出；OAV 仅在单位可比时计算，且不代表混合物中的实际贡献。若增加独立批次、原始评委评分或加标实验，应首先复核弱目标、风格敏感关系与缺陷味候选，再讨论可干预的工艺变量。

当前正文与图表冻结于已完成的稳健共识和化学核验结果；正在计算的最终感官模型归因完成后，将另存新版本复核非线性归因与四路融合，不覆盖本版本。