问题二模型建立与求解

摘要式结论

针对 50 个标准化感官维度的关键化合物识别，本文从 250 款啤酒的 231 项化学及理化测量中预先界定 218 个严格单体候选，在 10 次重复、每次 3 折的外层验证下比较边际关联、PLS/VIP、ElasticNet、图正则回归和非线性树模型，并对第一问最终感官模型开展模块与字段两级条件归因。最终答案采用总关联、500 次分层自助、风格校正和 22 次留一风格删除的四路稳健秩融合，每个感官维度输出 3 项，共 150 条；自助入选频率中位数为 0.428。第一问最终感官模型的宏平均 R^2、MAE 和 Spearman 为 0.2564、0.3361 和 0.4302，其归因仅作为独立预测依赖证据。化学核验得到 A/B/C/D 级关系 8/16/78/48 条；补充的三证据等权融合稳定性下降，故不替换正式 Top-3。

问题二分析

研究背景与任务界定

问题二要求对 50 个感官维度分别给出 3 个关键单体化合物，并同时论证结果的统计稳定性与化学合理性。附件 1 提供 250 款啤酒的 231 项化学及理化测量，附件 2 给出同一批字段的 Spearman 共表达矩阵，附件 4 提供 50 维标准化感官值。候选变量数与样本量接近，化合物又因共同代谢途径而高度共线，因此边际相关靠前并不等同于独立贡献，更不能直接解释为因果作用。

难点与证据链设计

本题的难点有三：共线字段会在重采样中相互替代；啤酒风格同时影响化学组成和感官评分，容易形成风格间关联；部分缺陷味与细分香气的折外可预测性较弱。本文先冻结 218 个严格单体候选，在相同的 10 次重复、每次 3 折外层划分下比较边际相关、稀疏回归和图正则回归，并对第一问最终感官模型做模块与字段两级条件归因。最终排序仍采用经分层自助、风格内校正和留一风格检验的稳健秩融合；统计排名冻结后，再用阈值、OAV、同名锚点和化学文献分级。

问题二模型

数据口径与候选范围

附件 1 与附件 4 按 beer 字段一一对齐，形成 250×231 的输入矩阵和 250×50 的连续感官矩阵。问题二不使用 beer_id 连接，不把风格字段作为候选化合物，也不对附件 1 中已给出的 log10 字段重复取对数。73 个缺失单元仅在相应训练子样本内用中位数填补，缺失位置在预测模型中保留指示。

候选资格先于统计建模冻结。色度、pH、苦度、蛋白质、总糖、热量、总酯、总酸、总硫及其他聚合或理化指标共 13 项不属于严格单体化合物，只参与全因素敏感性检查，不进入题面要求的最终 Top-3。严格候选因此为 218 项；化学名称由字段映射表与附件 8 逐项核对。表 1 概括数据和证据边界。

表 1 问题二数据契约与证据边界

项目	审计结果	处理方式	解释边界
样本与目标	250 款、50 维	固定 10×3 外层划分	逐目标折外评价
输入字段	231 项、73 个缺失	训练子样本内填补	不删除含缺失样本
严格候选	218 个单体	排除 13 个聚合/理化指标	全因素仅作敏感性
共表达矩阵	231×231 Spearman	描述图与折内图分开	验证时不复用全量图
感官值	标准化连续值	按附件尺度建模	不声称恢复原始 0—6 分
化学证据	阈值、来源、异味、文献	排名冻结后追加	不作因果解释

记第 i 款啤酒的化学向量为 x_i，第 j 个标准化感官值为 y_ij。关键化合物识别以式(1)所示预测关系为共同评价对象，但最终名次由相互独立的统计证据融合决定，而不是直接把某一模型的重要性当作因果效应。

$$y_{ij}=f_j\left(x_i\right)+\varepsilon_{ij},i=\ 1,\ldots,250,j=\ 1,\ldots,50 \tag{1}$$

边际关联、稀疏回归与折内图正则

第一类证据为逐目标 Spearman 边际关联。它保留单调非线性且对异常值较稳健，式(2)将化学字段和感官值的样本秩相关标准化。所有排名均先过滤为 218 个严格单体候选。

$$\rho_{kj}=\frac{\sum_{i=1}^{n}\left(R_{ik}-\overline{R}_k\right)\left(R_{ij}-\overline{R}_j\right)}{\sum_{i=1}^{n}\left(R_{ik}-\overline{R}_k\right)^{2}{}^{\frac{1}{2}}\sum_{i=1}^{n}\left(R_{ij}-\overline{R}_j\right)^{2}{}^{\frac{1}{2}}} \tag{2}$$

第二类证据为 ElasticNet 条件稀疏系数；第三类为加入有符号归一化图拉普拉斯的稀疏回归。图矩阵在每个外层训练折内重新估计，负边保留方向，缺失填补和标准化也只使用训练折。对目标 j，图正则目标函数写为式(3)。其中 L_s 为有符号图拉普拉斯，λ_1 控制稀疏度，λ_G 控制共表达邻居的系数平滑。

$$\hat{\beta}_j=arg\ \ min_{\beta}\left\{\frac{1}{2n}\left\|y_j-X\beta_j\right\|_2^{2}+\lambda_1\|\beta\|_1+\lambda_G\beta^{T}L_s\beta\right\} \tag{3}$$

图正则模型用于检验代谢共表达结构是否提高预测与排名稳定性。若折外误差没有改善，图结构仍可用于模块联合置换和解释，但不据此宣称预测增益。

最终感官模型的分层条件归因

第一问最终模型由 ExtraTrees、直方图梯度提升、秩高斯 Ridge 和秩高斯 PLS2 组成，并用带自由截距的非负最小二乘在香气、风味和味觉/口感/总体三个感官组内估计融合权重，再向共享权重收缩 0.5。问题二沿用第一问的 10×3 外层划分，在每个外层训练折中固定基学习器参数和融合权重，重建同一折预测器；归因阶段不重新选参，也不重新估计非负融合权重。

归因分两级进行。先将折内共表达模块整组置换，测量模块对 50 维感官预测的联合影响；再在模块内逐字段条件置换，只打乱观测值并保留原缺失掩码，以减弱模块内替代造成的重要性错配。若置换字段 k 后目标 j 的验证 MAE 上升，则式(4)的条件误差增量为正。

$$\Delta_{kj}^{cond}=MAE\left(y_j,\hat{f}_j\left(X_{-k},\tilde{x}_k\right)\right)-MAE\left(y_j,\hat{f}_j(X)\right) \tag{4}$$

30 个外层折的预测重建最大绝对误差为 1.998×10^{-15}。模块置换和模块内条件置换分别形成 13,900 条与 327,000 条折级汇总记录。两类误差增量只刻画冻结预测器对字段或模块的依赖，不直接等同于感官机理或因果效应。

四路稳健秩融合

三类基础方法先形成总关联共识，随后与分层自助稳定排名、风格校正排名、留一风格保留排名共同组成四路证据。对每个目标和候选，先比较四路 Top-10 与 Top-3 支持数，再计算式(5)的倒数秩分数；r_ℓkj 表示候选 k 在第ℓ类证据中对目标 j 的名次。

$$S_{kj}=\sum_{\ell=1}^{4}\frac{1}{60+r_{\ell kj}} \tag{5}$$

稳定性检验在 22 种啤酒风格内保持样本数进行 500 次有放回抽样。每次重新完成预处理、候选排序和方法融合，候选的入选频率按式(6)计算。与此同时，逐一删除 22 种风格并重算排名，以检验某一风格是否主导关系。

$$\pi_{kj}=\frac{1}{B}\sum_{b=1}^{B}I\left(k\in T_b^{j}\right) \tag{6}$$

化学合理性与证据分级

统计 Top-3 冻结后，才依据同名锚点、描述词特异性、附件来源/老化/异味注释及同行评议文献进行化学核验。仅当附件 8 同时提供原始校准浓度 c_k 和同字段、同单位感知阈值 τ_k 时，才按式(7)计算气味活性值。附件 1 中的 log10 数值不直接除以阈值。

$$OAV_k=\frac{c_k}{\tau_k},\tau_k>0 \tag{7}$$

A 级表示统计关系较稳健且有直接身份或特异描述词证据；B 级表示统计与化学类别证据较完整；C 级至少有一侧证据但特异性不足；D 级为弱预测背景或缺少特异化学支持。OAV 达到 1 仅说明单体浓度达到阈值量级，不排除混合物协同、掩蔽、基质与个体差异。

问题二求解

交叉验证与模型比较

所有监督模型复用问题一冻结的 10 次重复、每次 3 折外层划分；每个重复中 250 款啤酒各作为一次验证样本。参数、缺失填补、图结构、风格均值和条件分组均只由外层训练折估计。表 2 报告六种候选方法及最终感官模型的重复宏平均结果。图 1 突出相关阈值变化对正负边和网络连通结构的影响；图 2 分开呈现候选模型性能与正式 Top-3 对四路证据的一致性。

表 2 相同外层划分下的候选模型与最终感官模型性能

方法	R^2（均值±SD）	MAE（均值±SD）	RMSE	Spearman
全局均值	-0.0081±0.0024	0.4173±0.0005	0.5690	-0.0576
Spearman Top-3	0.1064±0.0043	0.3843±0.0010	0.5273	0.2969
PLS/VIP	0.2089±0.0069	0.3556±0.0015	0.4890	0.4023
ElasticNet	0.2086±0.0046	0.3529±0.0012	0.4903	0.3917
有符号图 ElasticNet	0.2084±0.0047	0.3530±0.0013	0.4905	0.3919
ExtraTrees 条件归因	0.2359±0.0058	0.3422±0.0011	0.4794	0.4144
感官组收缩 NNLS	0.2564±0.0070	0.3361±0.0016	0.4714	0.4302

最终感官模型的宏平均 R^2、MAE 和 Spearman 分别为 0.2564、0.3361 和 0.4302，优于独立 ExtraTrees 验证器的 0.2359、0.3422 和 0.4144。图正则模型相对 ElasticNet 的 MAE 增加 0.00011，因此图结构只用于模块与敏感性分析。最终感官模型承担预测归因，关键化合物答案仍由跨方法、重采样和风格扰动下更稳定的四路秩融合给出。

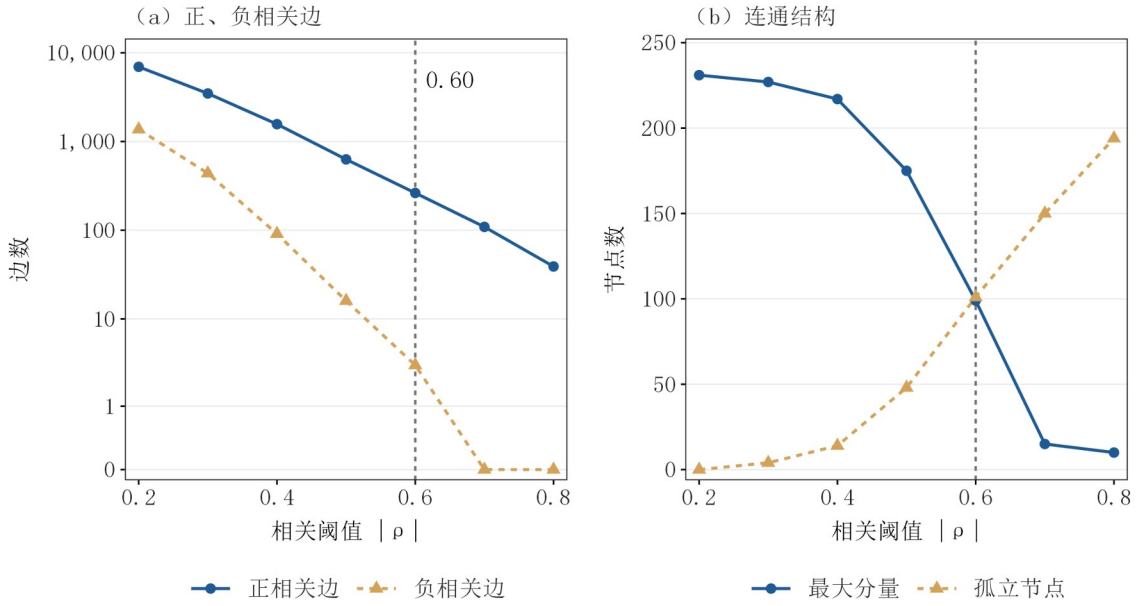


图 1 化合物共表达网络的阈值选择与结构敏感性

注：全量描述图；边数采用可包含零值的伪对数轴。虚线为既定阈值 0.60，正负边数为 264 和 2；全量描述图不参与折内监督验证。

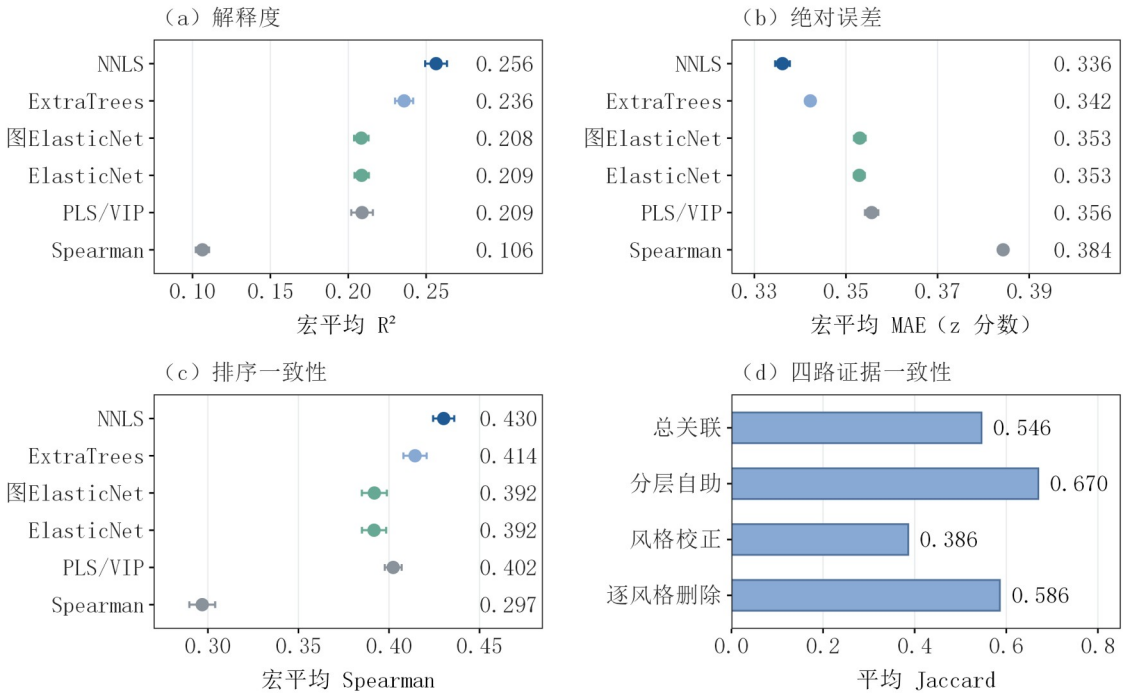


图 2 候选模型的折外性能与稳健排序的四路一致性

注：前三面板为 10 次重复的均值±标准差，短横线表示标准差。NNLS 指感官组收缩 NNLS，图 ElasticNet 指有符号图正则回归，ExtraTrees 为独立树验证器，Spearman 为边际关联 Top-3 预测器。点图坐标轴局部放大；MAE 越低越好，R^2 与 Spearman 越高越好。末面板为正式 Top-3 与四路证据的平均 Jaccard，不是预测性能。

稳定性与风格敏感性

500 次分层自助中，150 条聚合 Top-3 的入选频率范围为 0.182—0.992，中位数为 0.428；达到 0.60、0.70 和 0.80 的候选分别有 43、31 和 23 条。逐目标 Top-3 两两 Jaccard 均值为 0.245，说明共线字段替代和样本扰动不可忽略。稳定共聚类得到 170 个模块，其中 155 个为单字段模块，最大模块含 15 个字段。

相同参数下，未校正与风格校正 Top-3 的平均 Jaccard 为 0.264，只有 2/50 个目标完全一致。逐一删除 22 种风格后，1,100 个“风格—目标”组合的 Top-3 平均 Jaccard 为 0.523；当前 150 条候选在 22 次删除中的平均保留率为 0.641。图 3 按化学证据等级分别展示样本扰动与风格扰动下的稳定性分布。

补充的互补半样本检验按风格分层构造 100 对互补子样本，每个子样本重新填补、风格中心化并排序。入选频率不低于 0.60 的关系有 24 条；在 0.60—0.90 四个预设阈值下，风格内目标置换均未产生入选关系。互补 Top-3 的平均 Jaccard 仅为 0.085，说明排名尾部

仍有明显替代性。因此，论文同时报告确认关系与探索性关系，不把强制输出的 150 条关系写成同等可靠。

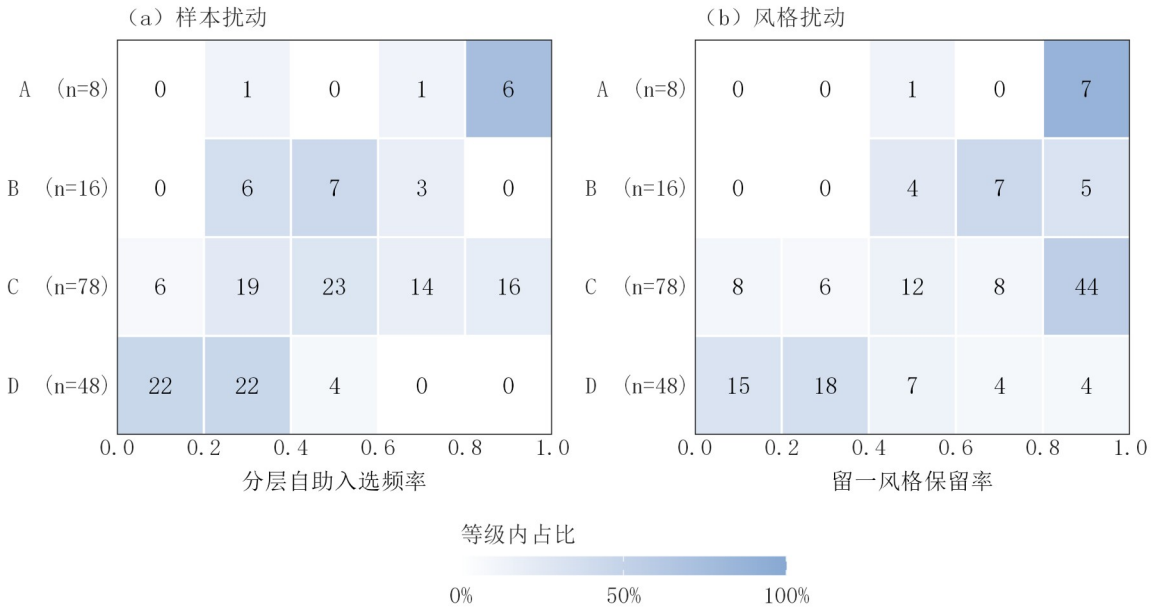


图 3 不同化学证据等级的样本与风格扰动稳定性

注：两面板均纳入全部 150 条关系。每格为对应等级内的关系数，底色为等级内比例；五个区间依次左闭右开，末区间包含 1。A/B/C/D 为既有化学核验等级，分箱只用于呈现，不改变等级或排序。

关键化合物与化学核验

四路融合的 150 条统计 Top-3 中，强稳健、中等稳健和探索性候选分别为 38、52 和 60 条；50 个目标中，22 个折外 R^2 不低于 0.20，12 个介于 0.10 与 0.20 之间，16 个低于 0.10。题面要求每个维度输出 3 项，因此弱预测目标仍保留候选，但必须标明探索性。

表 3 化学证据较充分的代表性关键关系

感官维度	名次	关键化合物	自助入选频率	留一风格保留率	中位 OAV
指甲油样香气	1	乙酸乙酯	0.774	1.000	1.203
指甲油样风味	1	乙酸乙酯	0.878	1.000	1.203
4-乙烯基愈创木酚	1	4-乙烯基愈创木酚	0.992	1.000	0.000
酸度	1	乳酸	0.900	0.955	0.346
酒精感	1	乙醇	0.920	0.955	4.140
酒体	2	乙醇	0.812	0.955	4.140
碳酸感	3	二氧化碳	0.318	0.500	不可比
乳酸感	1	乳酸	0.992	1.000	0.346

150 条候选的 A/B/C/D 级数量分别为 8、16、78 和 48，其中 73 条具备可比的浓度与阈值，23 条的中位 OAV 不低于 1。表 3 列出的 8 条 A 级关系包括乙酸乙酯—指甲油样酯香、4-乙烯基愈创木酚—同名感官、乳酸—酸度/乳酸感、乙醇—酒精感/酒体以及二氧化碳—碳酸感。图 4 展示这些关系在四路证据中的名次和可计算的中位 OAV。

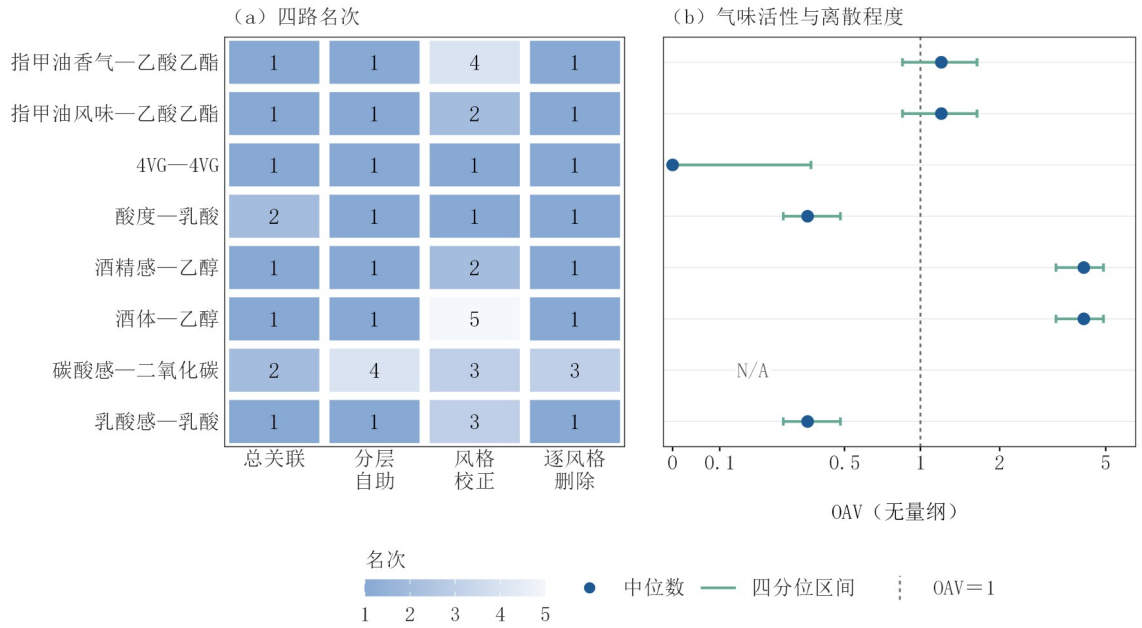


图 4 A 级化合物—感官关系的四路名次与气味活性值

注：左侧名次越小越靠前；右侧点为 OAV 中位数，横线为四分位区间。OAV 为无量纲浓度/阈值比，采用含零伪对数轴，虚线为 OAV=1；N/A 表示单位或阈值不可比，0 为零值，二者不等同。两面板关系按行对齐。4VG 为 4-乙烯基愈创木酚。

模型检验与结果讨论

泄漏与稳健性检验

验证折不参与缺失填补、尺度估计、图构建、风格均值、条件分组或参数选择；全量附件 2 仅用于数据定义核验与描述图。分层自助、风格校正和留一风格三种扰动从不同方向检验名次稳定性，字段级结果同时报告所属稳定模块，避免把同模块替代误写为唯一关键成分。

模型对比与消融

边际相关的宏平均 R^2 为 0.1064，说明单变量排序不足以概括多维感官信号；PLS/VIP 与 ElasticNet 提高到约 0.209，而加入有符号图惩罚后 R^2 为 0.2084、MAE 为 0.3530，

未获得额外预测收益。独立 ExtraTrees 验证器达到 0.2359，最终感官模型提高到 0.2564。图结构因此只承担模块、条件依赖和敏感性解释，不被写成预测增益。

将最终模型条件归因、折内偏相关和稳定模块三类证据等权融合后，候选 Top-3 的 CPSS 频率中位数、互补半样本 Jaccard 和留一风格生存率分别由 0.1425、0.1669、0.6591 降至 0.0750、0.1151、0.4091，并遗漏碳酸感的直接锚点。该方案作为失败消融保留，不进入正式排序；后续自动化化学分级也不生成正式答案。问题二最终结论仍是四路稳健统计 Top-3，最终感官模型归因只作为独立预测依赖证据。

表 4 把本文各方法家族与公开文献中的相应技术目的并列。文献数据的研究对象、样本尺度和评价任务与本题不同，因此文献指标不可直接横比；本表只比较方法能回答的问题、本文中的证据角色及采用边界。

表 4 公开方法与本文方法链的功能对照及消融结论

方法家族	回答的问题	本文对应结果	差异与采用判断
Spearman/加权相关网络 Zhang 与 Horvath（2005）	描述成对共变及模块结构	边际基线 R^2=0.1064；|ρ|=0.60 时保留 266 条描述性边	相关网络不区分直接与间接联系；全量图只作描述，监督验证中的图均由训练折估计。
稀疏回归与 graphical lasso Friedman 等（2008）	估计条件线性效应和稀疏条件依赖	ElasticNet R^2=0.2086；图正则 R^2=0.2084，折内偏相关模块用于结构审计	稀疏精度矩阵有助于排除部分间接边，但未改善正式排名的综合稳定性，故不替换四路排序。
树模型条件置换与 SHAP Strobl 等（2008）；Lundberg 与 Lee（2017）	解释非线性预测器依赖哪些变量	ExtraTrees R^2=0.2359；最终感官模型 R^2=0.2564，并完成模块—字段两级条件归因	SHAP 回答加性预测归因；本文共线性较强，采用模块联合与条件置换，归因只作预测依赖证据。
稳定选择与互补半样本 Meinshausen 与 Bühlmann（2010）；Shah 与 Samworth（2013）	评价变量选择在重采样下的可重复性与误选风险	500 次分层自助入选频率中位数 0.428；互补半样本与风格内置换用于补充检验	理论误选界依赖相应假设；本文将稳定频率用于分层和不确定性说明，不单独决定强制 Top-3。
四路稳健秩融合（本文）	综合总关联、样本扰动、风格内关系与跨风格生存性	输出 50×3 完整答案；R1/R2/R3 为 38/52/60 条，A/B/C/D 为 8/16/78/48 条	各路径只融合名次，不直接相加异质量纲的重要性；三证据等权方案稳定性下降，未被采用。

合理性与局限

4-乙烯基愈创木酚、乙醇、乳酸和二氧化碳等直接锚点进入最终 Top-3，支持方法能够恢复部分已知关系。DMS、双乙酰和 trans-2-nonenal 的同名字段未进入前三，分别排在较后位置，因此相应目标的前三只能解释为当前样本中的预测关联，不能冒充已知缺陷化合物。

本问仍受 250 个样本、22 种不均衡风格、共线替代和标准化感官信号限制。16 个弱预测目标的 Top-3 为题面要求下的探索性输出；OAV 仅在单位可比时计算，且不代表混

合物中的实际贡献。若增加独立批次、原始评委评分或加标实验，应首先复核弱目标、风格敏感关系与缺陷味候选，再讨论可干预的工艺变量。

最终感官模型的模块与字段两级归因已完成 30 折复核。归因结果支持把预测依赖与统计稳健性分开报告：前者回答冻结模型依赖哪些化学信息，后者决定每个感官维度的 Top-3。两类证据结论不一致时，以重采样和风格扰动下更稳定的排序作为题面答案。

问题二方法参考文献

[1] Zhang B, Horvath S. A general framework for weighted gene co-expression network analysis[J]. Statistical Applications in Genetics and Molecular Biology, 2005, 4: Article 17. DOI: 10.2202/1544-6115.1128.

[2] Friedman J, Hastie T, Tibshirani R. Sparse inverse covariance estimation with the graphical lasso[J]. Biostatistics, 2008, 9(3): 432-441. DOI: 10.1093/biostatistics/kxm045.

[3] Strobl C, Boulesteix A L, Kneib T, et al. Conditional variable importance for random forests[J]. BMC Bioinformatics, 2008, 9: 307. DOI: 10.1186/1471-2105-9-307.

[4] Meinshausen N, Bühlmann P. Stability selection[J]. Journal of the Royal Statistical Society: Series B, 2010, 72(4): 417-473. DOI: 10.1111/j.1467-9868.2010.00740.x.

[5] Shah R D, Samworth R J. Variable selection with error control: another look at stability selection[J]. Journal of the Royal Statistical Society: Series B, 2013, 75(1): 55-80. DOI: 10.1111/j.1467-9868.2011.01034.x.

[6] Lundberg S M, Lee S I. A unified approach to interpreting model predictions[C]//Advances in Neural Information Processing Systems 30. 2017: 4765-4774.