# 问题三模型建立与求解

## 摘要式结论

本文针对风格条件化合物谱生成、感官画像和跨风格迁移三个目标，使用风格内经验边缘与收缩相关结构构建联合生成模型，并将生成谱输入第一问最终感官组收缩 NNLS。每种目标风格生成 300 份谱，稳健尺度下 W1、联合 energy、留出覆盖率和对数离散误差分别为 0.4762、0.5813、0.5580 和 0.2475；Tripel、Kriek、Lambic 的画像呈现酒精/苦味/酒花/4VG 与酸度/乳酸感的清晰差异。33 组迁移任务中形成 2 条待实测统计候选，但未知浓度、检测地板和感官代理不稳定仍被单独标记，候选不等同于实测结果或物理安全认证。

## 问题三分析

### 研究背景与任务界定

问题三要求以 tasting_category_fine 为条件生成 Tripel、Kriek 和 Lambic 等风格的化合物谱，给出生成样本的感官画像，并把源啤酒迁移到目标风格，同时控制 DMS、双乙酰、4VG、trans-2-nonenal 和 Stale hops 等缺陷或代理指标不恶化。问题本质是高维联合分布生成、跨模型感官映射和带约束的化学空间搜索。

### 难点与证据链设计

本题的难点有三：231 个化学及理化字段对应的风格样本数只有 28、10、11；检测地板、缺失和参考值冲突使部分浓度不可直接比较；生成谱的感官画像与迁移收益都依赖第一问预测器，离开训练支持域后容易把模型外推误写成真实改善。本文先以折内边缘、相关结构和边界处理建立生成证据，再用留出分布指标、感官画像和化学可比性分层审计。

## 问题三模型

### 数据口径与预处理

以 beer 作为唯一连接键，beer_id 不参与建模。保留 250 个样本、231 个字段和原始缺失；对正值成对比对识别 37 个 log10 字段和 33 个原尺度字段，其余字段保持附件存储尺度。另行保存缺失掩码、校准零、参考冲突和可比观测状态。生成

与迁移中的分位、尺度、相关阵和边界均在训练折内估计，全量描述量只用于最终画像和图表。

表 1 问题三数据口径与处理规则

| 对象 | 处理规则 | 保留的边界 |
|---|---|---|
| 主键 | 按 beer 对齐化学谱、风格和感官数据 | beer_id 不连接、不建模 |
| 化学字段 | 按字段核验结果保留 log10 或原尺度 | 不对所有字段统一指数化 |
| 缺失/地板 | 保留缺失掩码和地板状态 | 未知浓度不作为安全上限 |
| 感官画像 | 使用第一问最终感官组收缩 NNLS | 0–6 仅作训练折经验映射 |
| 迁移约束 | 已知直接浓度逐项比较，未知项返回未知 | 未知不计入通过分母 |

## 风格条件收缩 Copula

设风格为 s，第 k 个字段的风格内经验分位函数为 Qsk。对风格内观测按字段取平均秩，并把秩映射到标准正态空间。

$$z_{ik} = \Phi^{-1}\left(\frac{r_{ik} - 0.5}{n_s}\right) \tag{1}$$

在潜在空间中，对风格内协方差向总体对角结构收缩；α s 由训练折内的稳定性准则确定，Ds 为协方差的对角阵，p 为字段数。

$$\hat{\Sigma}_s = (1 - \alpha_s)\Sigma_s + \alpha_s \frac{\mathrm{tr}(\Sigma_s)}{p}\mathrm{I} \tag{2}$$

$$R_s = {D_s}^{-1/2}\hat{\Sigma}_s{D_s}^{-1/2} \tag{3}$$

从标准正态相关分布采样后，按训练风格的经验边缘分位函数反变换，保留每个字段的非正态边缘并共享稳定的依赖结构。

$$x_k^* = Q_{sk}\left(\Phi(z_k^*)\right) \tag{4}$$

该模型不把三个目标风格的均值简单平移到同一空间，也不将生成尾部解释为实测浓度；评价同时使用边缘 W1、联合 energy、留出覆盖率、对数离散误差、秩相关误差和近训练复制率。

## 感官画像与相对等级

每个生成谱通过第一问最终感官组收缩 NNLS 得到 50 维标准化感官预测，再按对应训练折的经验分布做单调 0–6 映射。每种风格汇总 300 份生成谱的均值和第 10–90 百分位范围，该区间描述合成样本散布，不是均值置信区间。

表 2 三种风格生成样本的六维相对画像均值

| 维度 | Tripel | Kriek | Lambic |
|---|---|---|---|
| 酒精感 | 4.4 | 0.9 | 1.1 |
| 苦味 | 3.9 | 0.6 | 1.1 |
| 酒花味 | 3.7 | 0.8 | 1.6 |
| 4VG | 4.6 | 0.8 | 1.3 |
| 酸度 | 3.0 | 5.6 | 5.6 |
| 乳酸感 | 2.9 | 5.6 | 5.7 |

### 受约束迁移

设源谱为 x0，目标风格候选端点为 a，在化学设计空间中沿线性路径搜索候选谱。

$$x(\lambda) = (1 - \lambda)x_0 + \lambda a, \qquad 0 \le \lambda \le 1 \tag{5}$$

对 DMS、双乙酰、4VG 和 trans-2-nonenal，仅在源浓度可核验时施加不升约束；未知源值不填补为安全上限。

$$c_k^*(\lambda) = \min\big(c_k(x\lambda), c_k(x0)\big) \tag{6}$$

目标接近用目标风格相关结构下的距离衡量，谱改动用标准差归一化 RMS 衡量；两者是化学设计空间距离，不等同于酿造成本或实测迁移真值。

$$d_s(x) = \big(x - \mu_s\big)^{\mathrm{T}} R_s^{-1} \big(x - \mu_s\big) \tag{7}$$

$$\Delta(x, x_0) = \sqrt{\frac{\sum_{k=1}^{p}(x_k - x_{0k})^2}{p}} \tag{8}$$

## 问题三求解

### 交叉验证与模型比较

所有生成方法复用相同的 10 次重复、每次 3 折外层划分；边缘、相关阵、缺失处理和风格内参数均只由训练折估计。全数据最终生成仅用于三种目标风格的画像，不回写外层评价。

表 3 生成方法的稳健尺度比较

| 方法 | W1↓ | energy↓ | 覆盖率↑ | 离散误差↓ |
|---|---|---|---|---|
| 风格收缩 Copula | 0.4762 | 0.5813 | 0.5580 | 0.2475 |
| 整行局部混合 | 0.4740 | 0.5772 | 0.6599 | 0.2925 |
| PCA 邻域混合 | 0.4768 | 0.5805 | 0.6660 | 0.3026 |
| 基函数邻域混合 | 0.4786 | 0.5834 | 0.6580 | 0.3014 |

收缩 Copula 在 W1、联合 energy 和对数离散误差之间取得较均衡的结果；局部混合覆盖率更高，但离散误差同步增加。因此正文主线保留风格条件收缩 Copula，把局部混合作为覆盖敏感性比较。

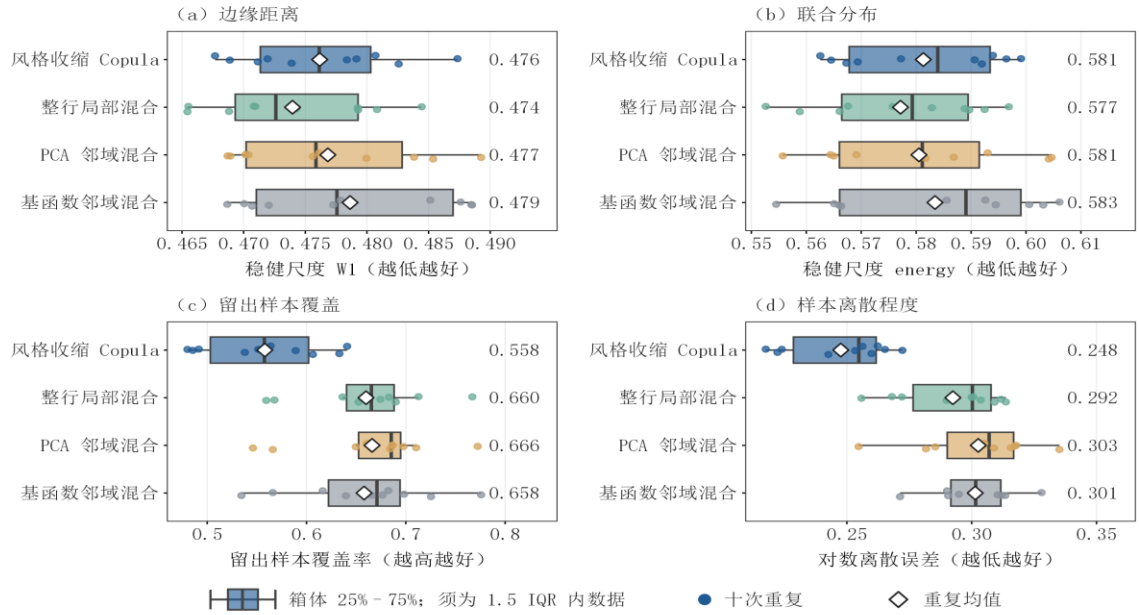



图 1 风格条件生成方法在外层重复验证中的分布保真与多样性

注：箱线为外层重复分布，点为重复结果，菱形为均值；W1、energy 和离散误差越低越好，覆盖率越高越好。

## 三风格感官画像

Tripel 在酒精感、苦味、酒花味和 4VG 上较高，Kriek 与 Lambic 在酸度和乳酸感上较高。图中误差棒表示 300 份生成样本的第 10–90 百分位范围；4VG 的第一问外折解释度约为 0.255，画像用于相对比较，不能替代真实品评。

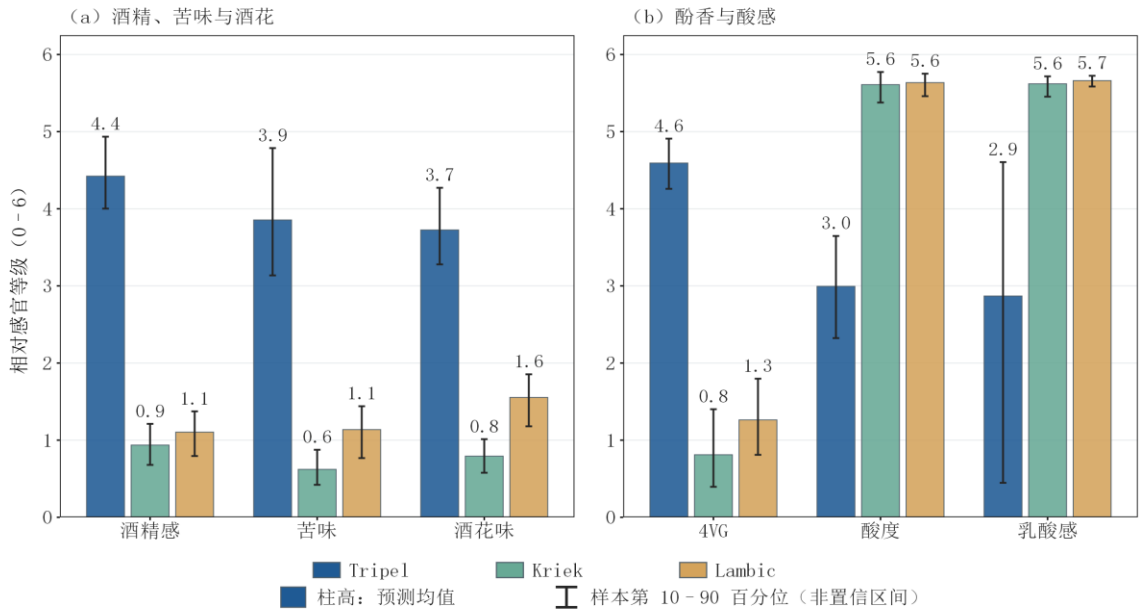



图 2 三目标风格生成样本的相对感官画像

注：柱高为生成样本均值，黑色误差棒为第 10–90 百分位范围；0–6 为训练折经验映射后的相对等级。

## 跨风格迁移与缺陷约束

33 组源—目标任务中，固定最小改动规则得到 29 条有谱候选：2 条进入待实测统计候选，26 条直接化学证据不足，1 条感官代理不稳定，4 组未找到搜索可行谱。两条候选均来自源啤酒 230，分别指向 Tripel 和 Kriek；目标距离分别下降 38.36%和 37.36%，谱 RMS 改动分别为 0.4862 和 0.5822。两条候选均未取得物理安全认证。

表 4 两条待实测统计候选的迁移结果

| 目标风格 | 目标距离下降 | 谱 RMS 改动 | 代理模型状态 | 化学状态 |
|---|---|---|---|---|
| Tripel | 38.36% | 0.4862 | 两模型预测不升 | 仍有待核验状态 |
| Kriek | 37.36% | 0.5822 | 两模型预测不升 | 仍有待核验状态 |

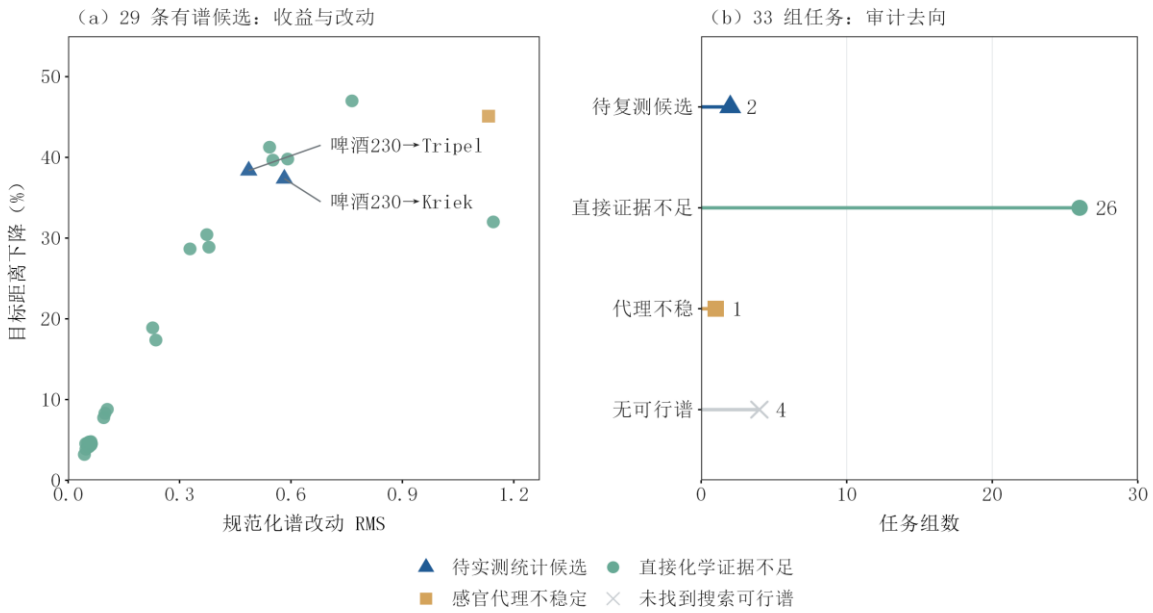



图 3 跨风格迁移候选的目标接近程度与证据状态

注：目标距离下降越大表示越接近目标风格；颜色和点形同时标记统计候选、直接证据不足、代理不稳定及无可行谱。

## 模型检验与结果讨论

### 泄漏与稳健性检验

验证折不参与缺失填补、边缘分位、尺度估计、相关阵、风格均值或迁移边界计算；近训练复制率为 0，完整谱重构误差处于 $10^{-12}$ 量级。未知浓度、检测地板和绝对阈值缺失分别保留未知状态，不能把缺失值计入缺陷约束通过率。

### 模型对比与消融

经验重采样和收缩高斯分别用于检查边缘与相关结构的必要性；局部混合、共享低秩、地板感知边缘和神经残差作为消融。局部混合提高覆盖率但增加离散误差，共享低秩和神经残差没有形成稳定的联合指标增益，故保留收缩 Copula 作为正文主线。公开文献中的 Copula 生成、协方差收缩、Mahalanobis 距离和约束搜索只用于说明方法边界，文献数字与本题任务不可直接横比。

表 5 生成与迁移方法的功能对照及消融结论

| 方法家族 | 回答的问题 | 本文对应结果 | 采用边界 |
| --- | --- | --- | --- |
| 经验边缘与 Copula | 如何保持非正态边缘和联合依赖 | 收缩 Copula 作为主生成方法 | 目标风格样本稀疏时依赖收缩 |
| 协方差收缩 | 如何稳定估计高维相关结构 | 风格内协方差向对角结构收缩 | 不把收缩后的相关解释为机理 |
| 局部混合/低秩结构 | 如何扩大覆盖或降维采样 | 作为消融，覆盖提升伴随离散误差 | 不能只凭覆盖率替换主模型 |
| Mahalanobis 约束搜索 | 如何度量目标接近与限制谱改动 | 用于迁移候选排序 | 候选须经过直接化学核验 |
| 强化学习或深度生成 | 如何学习长期动作或复杂生成策略 | 当前数据缺少动作—状态转移和独立实测 | 登记为后续研究，不进入本问主结果 |

## 补充检验：联合一致性、结构消融与迁移边界

为检验生成结果是否满足任务中的联合一致性要求，在冻结的三十个外层划分、三个目标风格和五个生成种子上核对完整性，并将检验结果汇总于表 6。全部 450 组生成记录与各自风格留出样本数匹配，训练与验证啤酒无交叉；900 份全数据描述画像的 45,000 个目标值全部有限。近训练复制率和整组塌缩标记均为 0。检测地板造成的原有恒定字段单独保留，不能用全部字段均有方差作为有效性条件。

进一步在每个固定缓存组内逐字段独立置换生成样本行，重复五次，保持每个字段的边缘值而打散化合物间配对。沿用训练折中位数、分位边界和尺度，逐组重算后原始稳健诊断与存档最大差为 $2.22\times10^{-16}$；置换前后的 W1 完全相同。图 4 显示，置换后 energy 平均增加 0.00109，相关结构 RMSE 平均增加 0.00851，覆盖率在三种风格均下降。Tripel 的 energy 增加 0.00275，但 Kriek 为−0.00009，说明保留联合配对得到的是有限且风格不一致的支持，不能据此声称所有风格的依赖结构均已准确恢复。

表 7 按实际结构比较共享低秩、风格残差收缩及风格残差与地板状态三种变体。三者的相关 RMSE 略有降低，但边缘 W1 和联合 energy 均增加，energy 相对主模型增加 0.0658–0.0703，故本题继续使用风格条件收缩 Copula。该结构消融说明，改善某一相关诊断并不必然改善联合分布。同时，原尺度与分位稳健尺度的距离差别明显，表 6 并列保留两种口径，避免由少量极端观测决定单一结论。

迁移检验区分策略记录和源—目标任务。早期直接约束阶段 891 条记录中 844 条有谱、47 条结构拒绝；293 条 Pareto 标记是并行属性。15 条等待代理接入记录代表当时尚未完成代理检查。当前固定最小改动主规则的 33 组任务仍按 2 条待实测统计候选、26 条直接证据不足、1 条代理不稳定和 4 条无谱报告。两条统计候选来自同一源；对同一锁定候选追加 0.01z 或 0.02z 的双模型下降裕量后，满足数均由 2 降为 0，表明结论处于代理误差边界。

全部重复标准差和图 4 横线只描述划分及随机扰动，折、种子或置换均不作为独立实测样本。当前验证限于已知目标风格内留出，未见风格外推、独立批次及实际酿造尚未检验；小风格画像只作描述，生成谱是与训练分布相容的统计设计，需在直接浓度、感官与工艺层面进一步验证。

表 6 问题三补充检验与适用范围

| 检验项 | 结果 | 口径与结论 |
| --- | --- | --- |
| 完整性与划分 | 30 折×3 风格×5 种子共 450 组齐全，生成数逐组匹配留出数；900 份画像×50 目标全部有限 | 训练与验证 beer 无交叉；支持程序一致性和画像完整性 |
| 复制与退化 | 近训练复制率 0，整组塌缩标记 0 | 复制按规范化 RMS≤$10^{-6}$；实测本已恒定的地板维度保留 |
| 尺度敏感性 | 原尺度 W1/energy=1.0773/6.3933；稳健尺度 0.4762/0.5813 | 稳健边界仅来自训练折 1%–99%分位；极端记录影响显著 |
| 逐风格一致性 | Tripel/Kriek/Lambic 稳健 W1 为 0.4114/0.5684/0.4487；覆盖 0.3356/0.7389/0.5994 | 风格等权；小风格相关 RMSE 较大，仅作描述 |
| 保持边缘的独立置换 | W1 变化 0；energy 差+0.00109，相关 RMSE 差+0.00851 | 差为置换−原谱；五次置换先平均；Kriek 的 energy 差为−0.00009，证据不一致 |
| 早期分母核验 | 891 记录=844 有谱+47 结构拒绝；844=512 直接证据不足+205 无收益+112 拒绝+15 待代理 | Pareto 标记 293 为并行属性；15 条当时仅等待代理接入 |
| 固定迁移与裕量 | 33 任务中 2 统计候选/26 证据不足/1 代理不稳/4 无谱；裕量 0/0.01/0.02z 对应 2/0/0 | 固定候选不重新选择；两候选来自同一源，需独立实测 |
| 未验证范围 | 未见风格泛化、独立批次和实际酿造尚未验证 | 已知风格内留出；不支持可实际酿造、唯一或全局最优主张 |

重复训练集高度重叠；种子、置换与折均先聚合到重复，重复标准差只描述扰动。覆盖率为真实留出点的近邻几何覆盖率，不是区间覆盖或安全率。早期记录和当前源—目标任务分母分别报告。

表 7 共享结构变体的生成消融检验

| 方法 | W1 / energy | 覆盖率 / 相关 RMSE |
| --- | --- | --- |
| 风格收缩 Copula | 0.4762 / 0.5813 | 0.5580 / 0.7748 |
| 共享低秩 | 0.5648 / 0.6516 | 0.5070 / 0.7706 |
| 风格残差收缩 | 0.5643 / 0.6471 | 0.4989 / 0.7723 |
| 风格残差与地板状态 | 0.5646 / 0.6471 | 0.4992 / 0.7723 |

同一 10×3 外层划分与五个生成种子，训练折分位稳健尺度；先对折和种子平均，再对三风格等权。W1、energy 与相关 RMSE 越低越好；覆盖须与离散和联合距离共同解释。三结构相对主模型的 energy 增加 0.0658–0.0703，相关 RMSE 略降。

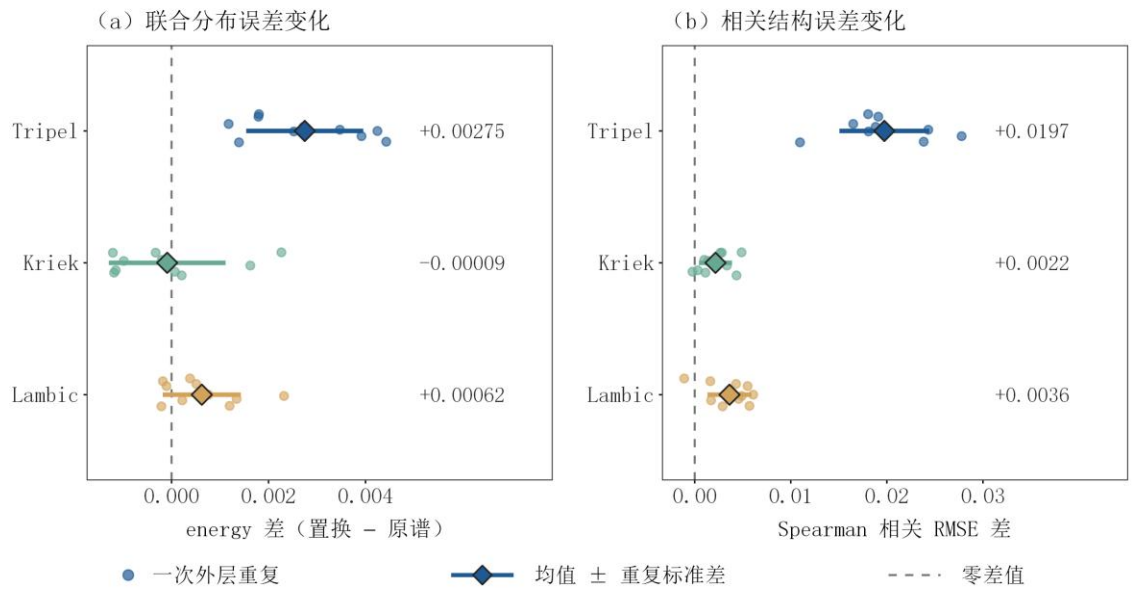



图 4 保持边缘分布的独立置换下三种风格的联合结构检验

差为置换减原谱；每点为一次外层重复，菱形与线段为十次重复均值±标准差。每折每风格五个生成种子、五次置换先平均；边缘 W1 按构造不变。正差支持保留联合配对，Kriek 的 energy 非正差同样保留。训练重复重叠，横线不是独立置信区间。

### 合理性与局限

生成画像复现了三种目标风格在酒精感、苦味、酒花味、4VG、酸度和乳酸感上的相对差异，说明化学空间到感官空间的映射具有可解释的方向性。迁移候选的“预测不升”只针对冻结感官预测器；Stale hops 的外层解释度约 0.03、平均绝对误差约 0.30 z，不能把预测变化直接等同于真实感官改善。

本问仍受 250 个样本、22 种不均衡风格、缺失/地板状态和缺少完整配方工艺的限制。两条迁移候选应作为待补测的统计设计，而不是可直接执行的酿造处方；若增加独立批次、原始浓度、检测限和感官评价，应重新进行端到端验证。

## 问题三方法参考文献

[1] Sklar A. Fonctions de répartition à n dimensions et leurs marges[J]. Publications de l'Institut de Statistique de l'Université de Paris, 1959.

[2] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 2004, 88(2): 365–411.

[3] Mahalanobis P C. On the generalized distance in statistics[J]. Proceedings of the National Institute of Sciences of India, 1936, 2: 49–55.

[4] Nelsen R B. An Introduction to Copulas[M]. 2nd ed. New York: Springer, 2006.

[5] Friedman J, Hastie T, Tibshirani R. Sparse inverse covariance estimation with the graphical lasso[J]. Biostatistics, 2008, 9(3): 432 – 441.

# 模型假设（问题三）

为简化问题，本文做出以下假设：

假设 1：同一化学字段在 250 款啤酒之间具有可比的测量含义。依据是附件 1 字段、附件 2 相关矩阵和附件 8 参考字段可以按 beer 对齐；若单位或批次漂移无法校准，则该字段只保留相对分布，不做绝对阈值判断。

假设 2：风格内经验边缘与收缩相关结构足以描述生成任务所需的联合变化。若留出联合距离或覆盖率明显恶化，则回退到经验重采样，并降低该风格画像的解释强度。

假设 3：检测地板、缺失值和参考冲突可以作为观测状态单独保留。若获得检测限、原始浓度或批次校准资料，应重建边缘并重新计算化学约束。

假设 4：第一问最终感官模型在训练支持域附近可提供带误差的相对画像。若迁移候选离开支持域或代理模型方向不稳定，则只保留为探索性统计候选，不写成真实感官改善。

假设 5：已知直接浓度约束下的最小改动路径可作为迁移候选的统计设计。该假设不代表配方、发酵工艺或物理安全；若要形成生产建议，必须增加独立批次、实测浓度和感官验证。

# 问题三分析

问题三要求以啤酒风格为条件生成合理的化合物谱，给出生成样本的感官画像，并将源啤酒迁移到目标风格，同时控制缺陷或代理指标不恶化。附件 1 提供 250 款啤酒的化学及理化字段，附件 4 提供标准化感官值，风格标签用于条件化建模。任务本质是高维联合分布生成、感官映射和带约束迁移的连续流程。

本题的难点有三：目标风格样本数较少而字段维数高，完整协方差容易不稳定；检测地板、缺失和参考冲突使部分绝对浓度不可比；迁移候选的感官变化依赖第一问预测器，模型外推不能直接当作真实改善。对此，本文在训练折内拟合经验边缘和收缩相关结构，以同一外层协议评价生成质量，再用感官画像、化学约束和证据状态分层报告迁移结果。