问题三模型建立与求解

摘要式结论

本文针对风格条件化合物谱生成、感官画像和跨风格迁移三个目标，使用风格内经验边缘与收缩相关结构构建联合生成模型，并将生成谱输入第一问最终感官组收缩 NNLS。每种目标风格生成 300 份谱，稳健尺度下 W1、联合 energy、留出覆盖率和对数离散误差分别为 0.4762、0.5813、0.5580 和 0.2475；Tripel、Kriek、Lambic 的画像呈现酒精/苦味/酒花/4VG 与酸度/乳酸感的清晰差异。33 组迁移任务中形成 2 条待实测统计候选，但未知浓度、检测地板和感官代理不稳定仍被单独标记，候选不等同于实测结果或物理安全认证。

问题三分析

研究背景与任务界定

问题三要求以 tasting_category_fine 为条件生成 Tripel、Kriek 和 Lambic 等风格的化合物谱，给出生成样本的感官画像，并把源啤酒迁移到目标风格，同时控制 DMS、双乙酰、4VG、trans-2-nonenal 和 Stale hops 等缺陷或代理指标不恶化。问题本质是高维联合分布生成、跨模型感官映射和带约束的化学空间搜索。

难点与证据链设计

本题的难点有三：231 个化学及理化字段对应的风格样本数只有 28、10、11；检测地板、缺失和参考值冲突使部分浓度不可直接比较；生成谱的感官画像与迁移收益都依赖第一问预测器，离开训练支持域后容易把模型外推误写成真实改善。本文先以折内边缘、相关结构和边界处理建立生成证据，再用留出分布指标、感官画像和化学可比性分层审计。

问题三模型

数据口径与预处理

以 beer 作为唯一连接键，beer_id 不参与建模。保留 250 个样本、231 个字段和原始缺失；对正值成对比对识别 37 个 log10 字段和 33 个原尺度字段，其余字段保持附件存储尺度。另行保存缺失掩码、校准零、参考冲突和可比观测状态。生成

与迁移中的分位、尺度、相关阵和边界均在训练折内估计，全量描述量只用于最终画像和图表。

表 1 问题三数据口径与处理规则

对象	处理规则	保留的边界
主键	按 beer 对齐化学谱、风格和感官数据	beer_id 不连接、不建模
化学字段	按字段核验结果保留 log10 或原尺度	不对所有字段统一指数化
缺失/地板	保留缺失掩码和地板状态	未知浓度不作为安全上限
感官画像	使用第一问最终感官组收缩 NNLS	0–6 仅作训练折经验映射
迁移约束	已知直接浓度逐项比较，未知项返回未知	未知不计入通过分母

风格条件收缩 Copula

设风格为 s，第 k 个字段的风格内经验分位函数为 Qsk。对风格内观测按字段取平均秩，并把秩映射到标准正态空间。

$$z_{ik} = \Phi^{-1}\left(\frac{r_{ik} - 0.5}{n_s}\right) \tag{1}$$

在潜在空间中，对风格内协方差向总体对角结构收缩；α s 由训练折内的稳定性准则确定，Ds 为协方差的对角阵，p 为字段数。

$$\hat{\Sigma}_s = (1 - \alpha_s)\Sigma_s + \alpha_s \frac{\mathrm{tr}(\Sigma_s)}{p}\mathrm{I} \tag{2}$$

$$R_s = {D_s}^{-1/2}\hat{\Sigma}_s{D_s}^{-1/2} \tag{3}$$

从标准正态相关分布采样后，按训练风格的经验边缘分位函数反变换，保留每个字段的非正态边缘并共享稳定的依赖结构。

$$x_k^* = Q_{sk}\left(\Phi(z_k^*)\right) \tag{4}$$

该模型不把三个目标风格的均值简单平移到同一空间，也不将生成尾部解释为实测浓度；评价同时使用边缘 W1、联合 energy、留出覆盖率、对数离散误差、秩相关误差和近训练复制率。

感官画像与相对等级

每个生成谱通过第一问最终感官组收缩 NNLS 得到 50 维标准化感官预测，再按对应训练折的经验分布做单调 0–6 映射。每种风格汇总 300 份生成谱的均值和第 10–90 百分位范围，该区间描述合成样本散布，不是均值置信区间。

表 2 三种风格生成样本的六维相对画像均值

维度	Tripel	Kriek	Lambic
酒精感	4.4	0.9	1.1
苦味	3.9	0.6	1.1
酒花味	3.7	0.8	1.6
4VG	4.6	0.8	1.3
酸度	3.0	5.6	5.6
乳酸感	2.9	5.6	5.7

受约束迁移

设源谱为 x0，目标风格候选端点为 a，在化学设计空间中沿线性路径搜索候选谱。

$$x(\lambda) = (1 - \lambda)x_0 + \lambda a, \qquad 0 \le \lambda \le 1 \tag{5}$$

对 DMS、双乙酰、4VG 和 trans-2-nonenal，仅在源浓度可核验时施加不升约束；未知源值不填补为安全上限。

$$c_k^*(\lambda) = \min\big(c_k(x\lambda), c_k(x0)\big) \tag{6}$$

目标接近用目标风格相关结构下的距离衡量，谱改动用标准差归一化 RMS 衡量；两者是化学设计空间距离，不等同于酿造成本或实测迁移真值。

$$d_s(x) = \big(x - \mu_s\big)^{\mathrm{T}} R_s^{-1} \big(x - \mu_s\big) \tag{7}$$

$$\Delta(x, x_0) = \sqrt{\frac{\sum_{k=1}^{p}(x_k - x_{0k})^2}{p}} \tag{8}$$

问题三求解

交叉验证与模型比较

所有生成方法复用相同的 10 次重复、每次 3 折外层划分；边缘、相关阵、缺失处理和风格内参数均只由训练折估计。全数据最终生成仅用于三种目标风格的画像，不回写外层评价。

表 3 生成方法的稳健尺度比较

方法	W1↓	energy↓	覆盖率↑	离散误差↓
风格收缩 Copula	0.4762	0.5813	0.5580	0.2475
整行局部混合	0.4740	0.5772	0.6599	0.2925
PCA 邻域混合	0.4768	0.5805	0.6660	0.3026
基函数邻域混合	0.4786	0.5834	0.6580	0.3014

收缩 Copula 在 W1、联合 energy 和对数离散误差之间取得较均衡的结果；局部混合覆盖率更高，但离散误差同步增加。因此正文主线保留风格条件收缩 Copula，把局部混合作为覆盖敏感性比较。

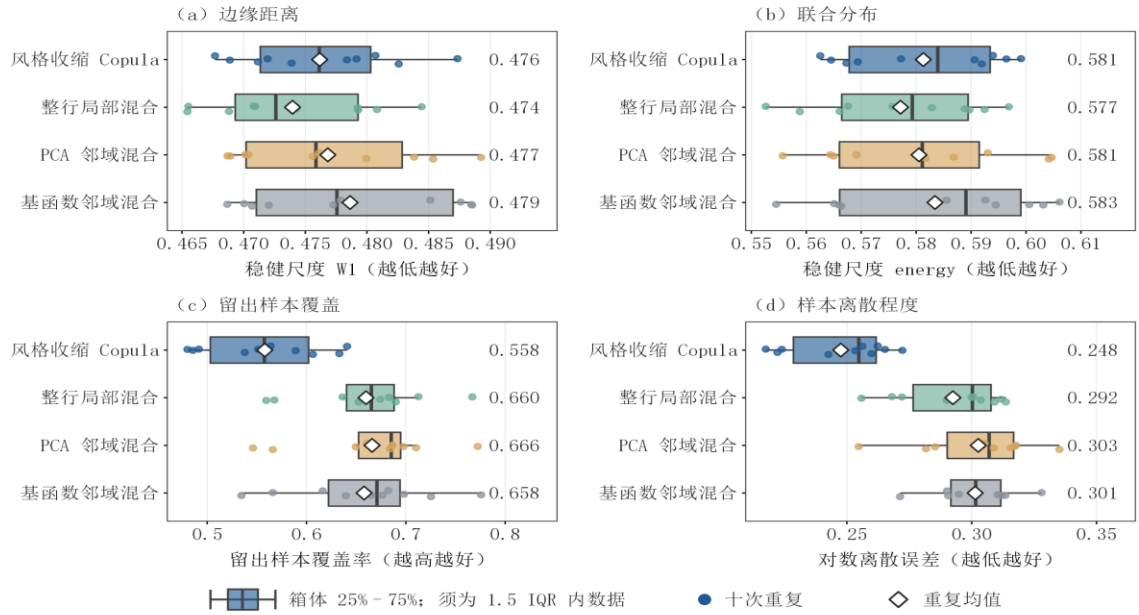


图 1 风格条件生成方法在外层重复验证中的分布保真与多样性

注：箱线为外层重复分布，点为重复结果，菱形为均值；W1、energy 和离散误差越低越好，覆盖率越高越好。

三风格感官画像

Tripel 在酒精感、苦味、酒花味和 4VG 上较高，Kriek 与 Lambic 在酸度和乳酸感上较高。图中误差棒表示 300 份生成样本的第 10–90 百分位范围；4VG 的第一问外折解释度约为 0.255，画像用于相对比较，不能替代真实品评。

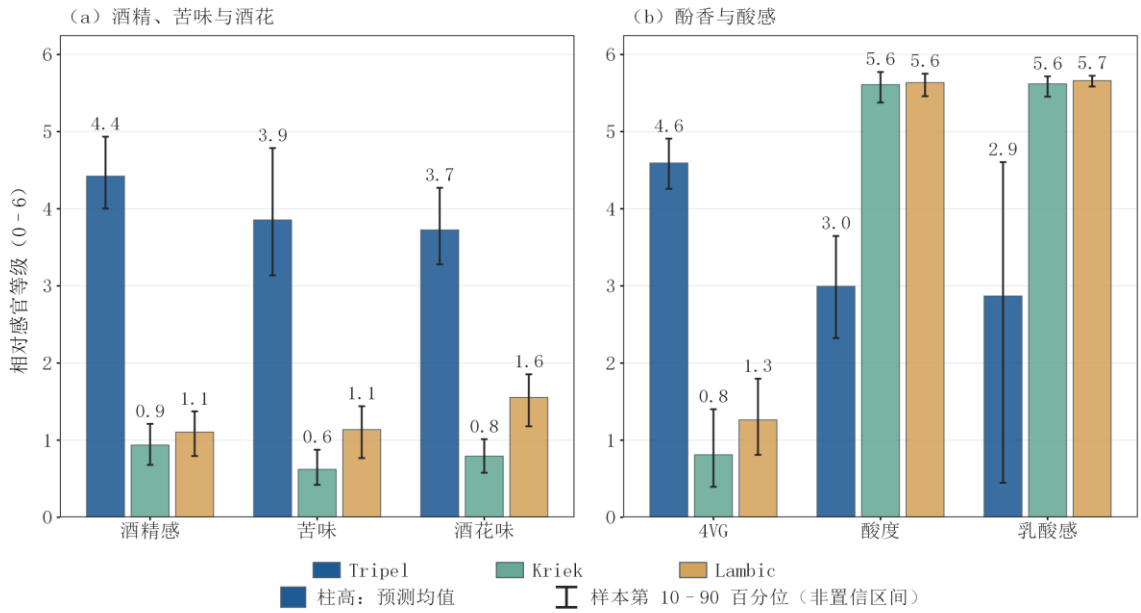


图 2 三目标风格生成样本的相对感官画像

注：柱高为生成样本均值，黑色误差棒为第 10–90 百分位范围；0–6 为训练折经验映射后的相对等级。

跨风格迁移与缺陷约束

33 组源—目标任务中，固定最小改动规则得到 29 条有谱候选：2 条进入待实测统计候选，26 条直接化学证据不足，1 条感官代理不稳定，4 组未找到搜索可行谱。两条候选均来自源啤酒 230，分别指向 Tripel 和 Kriek；目标距离分别下降 38.36%和 37.36%，谱 RMS 改动分别为 0.4862 和 0.5822。两条候选均未取得物理安全认证。

表 4 两条待实测统计候选的迁移结果

目标风格	目标距离下降	谱 RMS 改动	代理模型状态	化学状态
Tripel	38.36%	0.4862	两模型预测不升	仍有待核验状态
Kriek	37.36%	0.5822	两模型预测不升	仍有待核验状态

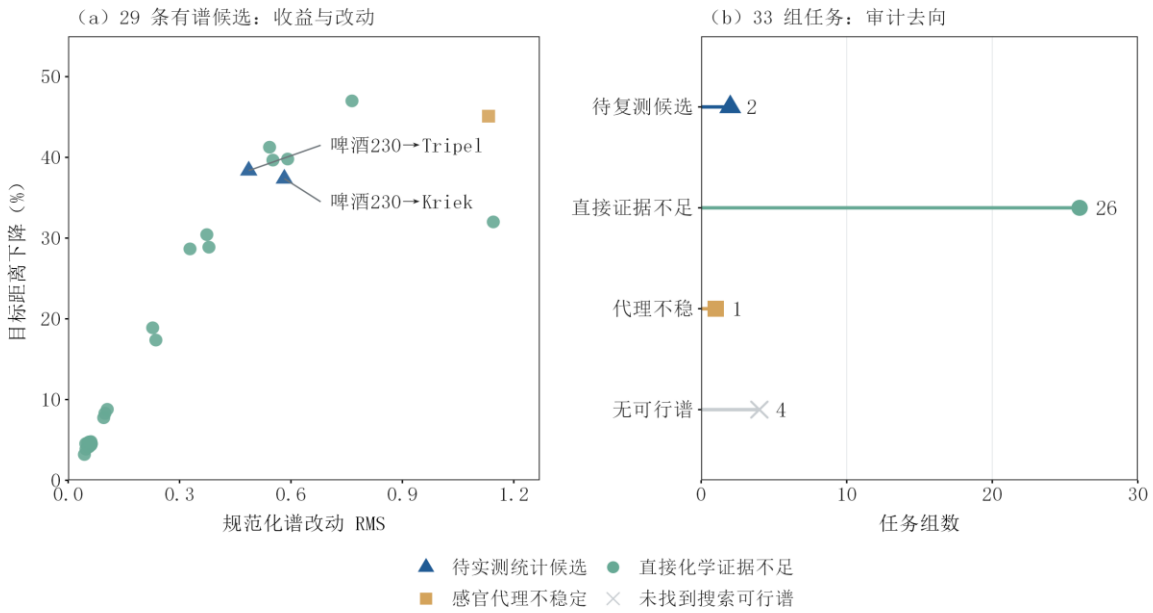


图 3 跨风格迁移候选的目标接近程度与证据状态

注：目标距离下降越大表示越接近目标风格；颜色和点形同时标记统计候选、直接证据不足、代理不稳定及无可行谱。

模型检验与结果讨论

泄漏与稳健性检验

验证折不参与缺失填补、边缘分位、尺度估计、相关阵、风格均值或迁移边界计算；近训练复制率为 0，完整谱重构误差处于 10^{-12} 量级。未知浓度、检测地板和绝对阈值缺失分别保留未知状态，不能把缺失值计入缺陷约束通过率。

模型对比与消融

经验重采样和收缩高斯分别用于检查边缘与相关结构的必要性；局部混合、共享低秩、地板感知边缘和神经残差作为消融。局部混合提高覆盖率但增加离散误差，共享低秩和神经残差没有形成稳定的联合指标增益，故保留收缩 Copula 作为正文主线。公开文献中的 Copula 生成、协方差收缩、Mahalanobis 距离和约束搜索只用于说明方法边界，文献数字与本题任务不可直接横比。

表 5 生成与迁移方法的功能对照及消融结论

方法家族	回答的问题	本文对应结果	采用边界
经验边缘与 Copula	如何保持非正态边缘和联合依赖	收缩 Copula 作为主生成方法	目标风格样本稀疏时依赖收缩
协方差收缩	如何稳定估计高维相关结构	风格内协方差向对角结构收缩	不把收缩后的相关解释为机理
局部混合/低秩结构	如何扩大覆盖或降维采样	作为消融，覆盖提升伴随离散误差	不能只凭覆盖率替换主模型
Mahalanobis 约束搜索	如何度量目标接近与限制谱改动	用于迁移候选排序	候选须经过直接化学核验
强化学习或深度生成	如何学习长期动作或复杂生成策略	当前数据缺少动作—状态转移和独立实测	登记为后续研究，不进入本问主结果

补充检验：联合一致性、结构消融与迁移边界

为检验生成结果是否满足任务中的联合一致性要求，在冻结的三十个外层划分、三个目标风格和五个生成种子上核对完整性，并将检验结果汇总于表 6。全部 450 组生成记录与各自风格留出样本数匹配，训练与验证啤酒无交叉；900 份全数据描述画像的 45,000 个目标值全部有限。近训练复制率和整组塌缩标记均为 0。检测地板造成的原有恒定字段单独保留，不能用全部字段均有方差作为有效性条件。

进一步在每个固定缓存组内逐字段独立置换生成样本行，重复五次，保持每个字段的边缘值而打散化合物间配对。沿用训练折中位数、分位边界和尺度，逐组重算后原始稳健诊断与存档最大差为 2.22×10^{-16}；置换前后的 W1 完全相同。图 4 显示，置换后 energy 平均增加 0.00109，相关结构 RMSE 平均增加 0.00851，覆盖率在三种风格均下降。Tripel 的 energy 增加 0.00275，但 Kriek 为−0.00009，说明保留联合配对得到的是有限且风格不一致的支持，不能据此声称所有风格的依赖结构均已准确恢复。

表 7 按实际结构比较共享低秩、风格残差收缩及风格残差与地板状态三种变体。三者的相关 RMSE 略有降低，但边缘 W1 和联合 energy 均增加，energy 相对主模型增加 0.0658–0.0703，故本题继续使用风格条件收缩 Copula。该结构消融说明，改善某一相关诊断并不必然改善联合分布。同时，原尺度与分位稳健尺度的距离差别明显，表 6 并列保留两种口径，避免由少量极端观测决定单一结论。

迁移检验区分策略记录和源—目标任务。早期直接约束阶段 891 条记录中 844 条有谱、47 条结构拒绝；293 条 Pareto 标记是并行属性。15 条等待代理接入记录代表当时尚未完成代理检查。当前固定最小改动主规则的 33 组任务仍按 2 条待实测统计候选、26 条直接证据不足、1 条代理不稳定和 4 条无谱报告。两条统计候选来自同一源；对同一锁定候选追加 0.01z 或 0.02z 的双模型下降裕量后，满足数均由 2 降为 0，表明结论处于代理误差边界。

全部重复标准差和图 4 横线只描述划分及随机扰动，折、种子或置换均不作为独立实测样本。当前验证限于已知目标风格内留出，未见风格外推、独立批次及实际酿造尚未检验；小风格画像只作描述，生成谱是与训练分布相容的统计设计，需在直接浓度、感官与工艺层面进一步验证。

表 6 问题三补充检验与适用范围

检验项	结果	口径与结论
完整性与划分	30 折×3 风格×5 种子共 450 组齐全，生成数逐组匹配留出数；900 份画像×50 目标全部有限	训练与验证 beer 无交叉；支持程序一致性和画像完整性
复制与退化	近训练复制率 0，整组塌缩标记 0	复制按规范化 RMS≤10^{-6}；实测本已恒定的地板维度保留
尺度敏感性	原尺度 W1/energy=1.0773/6.3933；稳健尺度 0.4762/0.5813	稳健边界仅来自训练折 1%–99%分位；极端记录影响显著
逐风格一致性	Tripel/Kriek/Lambic 稳健 W1 为 0.4114/0.5684/0.4487；覆盖 0.3356/0.7389/0.5994	风格等权；小风格相关 RMSE 较大，仅作描述
保持边缘的独立置换	W1 变化 0；energy 差+0.00109，相关 RMSE 差+0.00851	差为置换−原谱；五次置换先平均；Kriek 的 energy 差为−0.00009，证据不一致
早期分母核验	891 记录=844 有谱+47 结构拒绝；844=512 直接证据不足+205 无收益+112 拒绝+15 待代理	Pareto 标记 293 为并行属性；15 条当时仅等待代理接入
固定迁移与裕量	33 任务中 2 统计候选/26 证据不足/1 代理不稳/4 无谱；裕量 0/0.01/0.02z 对应 2/0/0	固定候选不重新选择；两候选来自同一源，需独立实测
未验证范围	未见风格泛化、独立批次和实际酿造尚未验证	已知风格内留出；不支持可实际酿造、唯一或全局最优主张

重复训练集高度重叠；种子、置换与折均先聚合到重复，重复标准差只描述扰动。覆盖率为真实留出点的近邻几何覆盖率，不是区间覆盖或安全率。早期记录和当前源—目标任务分母分别报告。

表 7 共享结构变体的生成消融检验

方法	W1 / energy	覆盖率 / 相关 RMSE
风格收缩 Copula	0.4762 / 0.5813	0.5580 / 0.7748
共享低秩	0.5648 / 0.6516	0.5070 / 0.7706
风格残差收缩	0.5643 / 0.6471	0.4989 / 0.7723
风格残差与地板状态	0.5646 / 0.6471	0.4992 / 0.7723

同一 10×3 外层划分与五个生成种子，训练折分位稳健尺度；先对折和种子平均，再对三风格等权。W1、energy 与相关 RMSE 越低越好；覆盖须与离散和联合距离共同解释。三结构相对主模型的 energy 增加 0.0658–0.0703，相关 RMSE 略降。

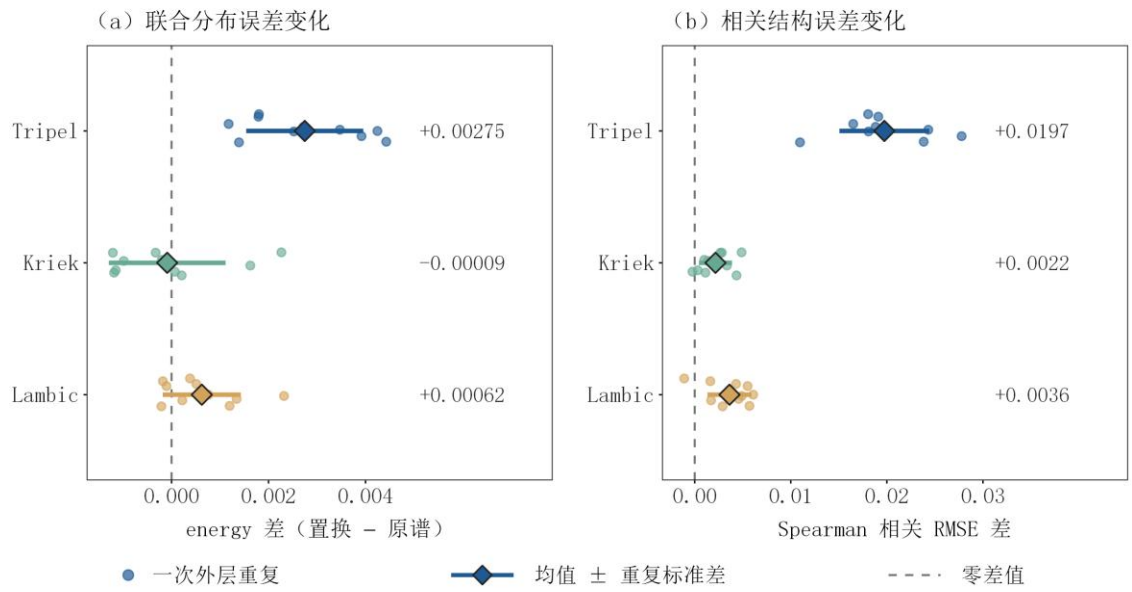


图 4 保持边缘分布的独立置换下三种风格的联合结构检验

差为置换减原谱；每点为一次外层重复，菱形与线段为十次重复均值±标准差。每折每风格五个生成种子、五次置换先平均；边缘 W1 按构造不变。正差支持保留联合配对，Kriek 的 energy 非正差同样保留。训练重复重叠，横线不是独立置信区间。

合理性与局限

生成画像复现了三种目标风格在酒精感、苦味、酒花味、4VG、酸度和乳酸感上的相对差异，说明化学空间到感官空间的映射具有可解释的方向性。迁移候选的“预测不升”只针对冻结感官预测器；Stale hops 的外层解释度约 0.03、平均绝对误差约 0.30 z，不能把预测变化直接等同于真实感官改善。

本问仍受 250 个样本、22 种不均衡风格、缺失/地板状态和缺少完整配方工艺的限制。两条迁移候选应作为待补测的统计设计，而不是可直接执行的酿造处方；若增加独立批次、原始浓度、检测限和感官评价，应重新进行端到端验证。

问题三方法参考文献

[1] Sklar A. Fonctions de répartition à n dimensions et leurs marges[J]. Publications de l'Institut de Statistique de l'Université de Paris, 1959.

[2] Ledoit O, Wolf M. A well-conditioned estimator for large-dimensional covariance matrices[J]. Journal of Multivariate Analysis, 2004, 88(2): 365–411.

[3] Mahalanobis P C. On the generalized distance in statistics[J]. Proceedings of the National Institute of Sciences of India, 1936, 2: 49–55.

[4] Nelsen R B. An Introduction to Copulas[M]. 2nd ed. New York: Springer, 2006.

[5] Friedman J, Hastie T, Tibshirani R. Sparse inverse covariance estimation with the graphical lasso[J]. Biostatistics, 2008, 9(3): 432 – 441.